




Συστήματα Αναμονής (Queuing Systems)

6η Ομάδα Ασκήσεων

Dataset

Στο αρχείο dataset.mat υπάρχουν τα δεδομένα που θα χρησιμοποιηθούν στα πλαίσια της άσκησης. Τα δεδομένα προέρχονται από ένα ανοιχτό dataset, το οποίο αποτελείται από καταγραφές για το φόρτο εργασίας σε data centers. Συγκεκριμένα, τα δεδομένα του αρχείου αφορούν το πλήθος των πόρων (συγκεκριμένα, GPU) που ζητούνται από τις εργασίες που φτάνουν στο σύστημα. Οι καταγραφές πραγματοποιούνται ανά ώρα και εκτείνονται σε ένα διάστημα δύο μηνών. Στο αρχείο που σας δίνεται, μόνο οι πρώτες 52 μέρες είναι διαθέσιμες. Στην ακόλουθη γραφική απεικονίζεται ένα υποσύνολο των δεδομένων για ορίζοντα μίας εβδομάδας.



Σχήμα 1: Απεικόνιση των δεδομένων για διάστημα μίας εβδομάδας.

Άσκηση

Στο κύριο μέρος της άσκησης θα χρησιμοποιήσετε τα δεδομένα των πρώτων 50 ημερών (1200 ωρών) ως ιστορικά δεδομένα, για να προβλέψετε το πλήθος των πόρων που θα ζητηθούν τις αμέσως επόμενες 48 ώρες (1201-1248). Στο αρχείο filter_forecasting.m δίνεται ως παράδειγμα ένα μοντέλο βασισμένο σε differencing και deseasonalizing φίλτρα, το οποίο έχει τη μορφή $Y = \Delta_1 \Delta_T X$. Αντίστοιχα, στο αρχείο regression_forecasting.m σας δίνεται ένα μοντέλο γραμμικής παλινδρόμησης (linear regression). Βασισμένοι στα μοντέλα που δίνονται, δοκιμάστε να κατασκευάσετε το δικό σας μοντέλο προβλέψεων, ένα για κάθε μέθοδο. Το μοντέλο σας θα πρέπει να υπολογίζει επίσης 95% διαστήματα πρόβλεψης. Σε μία κοινή γραφική παρουσίαστε τις προβλέψεις και τα διαστήματα πρόβλεψης που δίνει το μοντέλο σας, μαζί με τις πραγματικές τιμές. Συγκρίνετε τα αποτελέσματα μεταξύ των δύο μεθόδων.

Διαγωνισμός (Προαιρετική Συμμετοχή)

Στα πλαίσια της άσκησης θα πραγματοποιηθεί διαγωνισμός για τα μοντέλα πρόβλεψης στον οποίο μπορείτε να συμμετέχετε προαιρετικά. Στο συγκεκριμένο μέρος, μπορείτε να χρησιμοποιήσετε το σύνολο του dataset.mat για να κατασκευάσετε ένα μοντέλο πρόβλεψης, το οποίο θα πρέπει να εξηγήσετε επαρκώς στην αναφορά σας. Ο

κώδικας θα πρέπει να έχει τη μορφή συνάρτησης που θα παίρνει ως είσοδο μια χρονική στιγμή t και θα δίνει ως έξοδο ένα 95% διάστημα πρόβλεψης $[y_{\min}, y_{\max}]$ για τη χρονική στιγμή αυτή. Θεωρούμε ότι η χρονική στιγμή $t = 1$ αντιστοιχεί στο πρώτο δείγμα του δοθέντος dataset.

Ο διαγωνισμός θα γίνει σε δεδομένα που αφορούν μεταγενέστερες χρονικές στιγμές του dataset.mat και συγκεκριμένα τις ώρες από 1249 έως 1505 τις οποίες δεν έχετε στη διάθεσή σας. Όπως γνωρίζετε και από τη θεωρία του μαθήματος, το μοντέλο που ταιριάζει περισσότερο στα δεδομένα δεν είναι απαραίτητα το καλύτερο για προβλέψεις. Για αυτό, μπορείτε να χρησιμοποιήσετε οποιαδήποτε μεθοδολογία θεωρείτε κατάλληλη για να βελτιώσετε τις προβλέψεις σας και να την περιγράψετε στην αναφορά σας. Αν θέλετε να συμμετέχετε, θα χρειαστεί να συμπεριλάβετε στην υποβολή σας ξεχωριστό αρχείο κώδικα για αυτό το μέρος και στην αναφορά σας να δώσετε αναλυτικές οδηγίες εκτέλεσης για τον υπολογισμό του διαστήματος πρόβλεψης για μια χρονική στιγμή $t \in [1249, 1505]$.

Μία μετρική που χρησιμοποιείται ευρέως για την αξιολόγηση πιθανοτικών προβλέψεων ονομάζεται Continuous Ranked Probabilistic Score (CRPS) και ορίζεται ως

$$CRPS(F, x) = \int_{-\infty}^{+\infty} (F(y) - \mathbf{1}_{(y-x)})^2 dy,$$

όπου x η παρατηρούμενη τιμή, F η αθροιστική συνάρτηση κατανομής που αντιστοιχεί στην κατανομή που χρησιμοποιήθηκε για την πρόβλεψη και $\mathbf{1}_{(y-x)} = \begin{cases} 1, & y \geq x, \\ 0, & \text{αλλιώς} \end{cases}$. Όταν η συνάρτηση κατανομής είναι η κανονική με παραμέτρους μ και σ , δηλαδή $\mathcal{N}(\mu, \sigma^2)$, τότε η μετρική CRPS μπορεί να υπολογιστεί από τον ακόλουθο τύπο:

$$CRPS(\mathcal{N}(\mu, \sigma^2), x) = \sigma \left(\frac{x - \mu}{\sigma} \left(2\Phi \left(\frac{x - \mu}{\sigma} \right) - 1 \right) + 2\phi \left(\frac{x - \mu}{\sigma} \right) - \frac{1}{\sqrt{\pi}} \right),$$

όπου Φ, ϕ η αθροιστική συνάρτηση κατανομής και η συνάρτηση πυκνότητας πιθανότητας για την τυποποιημένη κανονική κατανομή, αντίστοιχα. Μικρότερες τιμές της μετρικής δηλώνουν καλύτερες προβλέψεις.

Για την αξιολόγηση των προβλέψεων σας, θα θεωρήσουμε ότι τα διαστήματα πρόβλεψης που δίνει το μοντέλο έχουν υπολογιστεί υποθέτοντας κανονική κατανομή και βάσει αυτού, θα υπολογιστεί η τιμή της μετρικής για τρεις επιλεγμένες μελλοντικές στιγμές από τις ώρες 1249 έως 1505.

Το μοντέλο που θα παρουσιάζει τη μικρότερη διάμεσο στα 3 δείγματα είναι και αυτό που θα κερδίζει ένα μικρό βραβείο-δώρο! Σε περίπτωση ισοβαθμίας θα μετρήσει και η ποιότητα των εξηγήσεων στην αναφορά ώστε να επιλεγεί ένας νικητής.