



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ - ΕΜΠ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ & ΜΗΧ. ΥΠΟΛΟΓΙΣΤΩΝ
Τομέας Επικοινωνιών, Ηλεκτρονικής & Συστημάτων Πληροφορικής
Εργαστήριο Διαχείρισης & Βελτίστου Σχεδιασμού Δικτύων Τηλεματικής - NETMODE

ΣΥΣΤΗΜΑΤΑ ΑΝΑΜΟΝΗΣ (6^η άσκηση)

Lab6 - FORECASTING

6^ο Εξάμηνο
Μάιος 2026

Forecasting

- Το forecasting είναι η διαδικασία εκτίμησης μελλοντικών τιμών βασισμένη σε ιστορικά δεδομένα
 - δεν δίνει τέλειες προβλέψεις
 - πάντα συνοδεύεται από **αβεβαιότητα**
- Γιατί είναι σημαντικό το Forecasting
Παραδείγματα:
 - Capacity planning
 - Βελτιστοποίηση πόρων
- Παράδειγμα: Για το σχεδιασμό ενός δικτύου υπολογιστών θέλουμε να ξέρουμε πόση κίνηση (traffic) θα έχουμε
 - Αν το υποτιμήσουμε έχουμε συμφόρηση,
 - αν το υπερεκτιμήσουμε σπαταλάμε πόρους του δικτύου

Δύο Μέθοδοι για Forecasting στην άσκησή μας

- **Linear Regression** - μέθοδος που προσεγγίζει δεδομένα με γραμμική σχέση, βρίσκει μια ευθεία γραμμή που ελαχιστοποιεί τη διαφορά ανάμεσα στις προβλεπόμενες τιμές και στις πραγματικές τιμές των δεδομένων
- **Filters** - μέθοδος που αφαιρεί τάση/εποχικότητα από χρονοσειρές, ουσιαστικά μειώνει το θόρυβο και εστιάζεις στα ουσιαστικά δεδομένα
- *Η μέθοδος Regression δείχνει μοτίβα, εξηγεί το μοντέλο/σήμα, ενώ η μέθοδος filters προσπαθεί να μετασχηματίσει το μοντέλο/σήμα και στη συνέχεια να το προβλέψει*

Linear Regression — Βασικές Έννοιες - Υπενθύμιση

•Εύρεση μοντέλου

- Στόχος: να βρούμε μια μαθηματική σχέση που περιγράφει τα δεδομένα, τα δεδομένα μοντελοποιούνται ως $Y = f(\theta) + \text{noise}$, στόχος η εκτίμηση των παραμέτρων θ , ο θόρυβος εκφράζει την αβεβαιότητα

•Δεδομένα με θόρυβο

- Τα πραγματικά δεδομένα περιέχουν τυχαίες αποκλίσεις που δεν μπορούν να εξηγηθούν από το μοντέλο και αντιμετωπίζονται ως θόρυβος
- Παραδειγμα: σε data center κάποια εργασία μπορεί να ζητήσει πολλές GPU (αυτό είναι θόρυβος) ή μια διακοπή στο σύστημα κλπ.

•Ελαχιστοποίηση σφάλματος (Least Squares)

- Επιλέγουμε τις παραμέτρους του μοντέλου ώστε να ελαχιστοποιείται το άθροισμα των τετραγώνων των σφαλμάτων μεταξύ πραγματικών και προβλεπόμενων τιμών

•Intuition (Διαίσθηση)

- Βρίσκουμε τη γραμμή ή καμπύλη που προσεγγίζει καλύτερα τα δεδομένα, δηλαδή περνάει όσο πιο κοντά γίνεται από όλα τα σημεία, ελαχιστοποιώντας το συνολικό σφάλμα

•Maximum Likelihood (Μέγιστη Πιθανοφάνεια)

- Είναι μέθοδος εκτίμησης παραμέτρων όπου επιλέγουμε τις τιμές των παραμέτρων που μεγιστοποιούν την πιθανότητα να παρατηρηθούν τα δεδομένα που έχουμε

•Residuals (κατάλοιπα-σφάλματα)

- Διαφορά πραγματικής τιμής και πρόβλεψης, πόσο λάθος έκανε το μοντέλο, πρέπει να έχουν μηδενική μέση τιμή και σταθερή διασπορά

$residual = \text{πραγματικό} - \text{πρόβλεψη}$, πραγματική τιμή 100 – πρόβλεψη 90 = 10 σφάλμα

Μέθοδος 1: Linear Regression – Υπενθύμιση

Supervised learning (Επιβλεπόμενη μάθηση) είναι μέθοδος όπου το μοντέλο εκπαιδεύεται με δεδομένα που περιλαμβάνουν τόσο εισόδους όσο και τις αντίστοιχες σωστές εξόδους, ώστε να μάθει τη μεταξύ τους σχέση και να κάνει προβλέψεις σε νέα δεδομένα

Στόχος του supervised learning είναι το μοντέλο να μάθει τη σχέση ανάμεσα στις εισόδους και τις σωστές εξόδους, ώστε όταν του δοθούν νέα, άγνωστα δεδομένα, να μπορεί να προβλέψει σωστά την απάντηση

Η **Linear Regression (Γραμμική Παλινδρόμηση)** είναι ένας αλγόριθμος supervised learning που χρησιμοποιείται για να προβλέπει μια συνεχόμενη αριθμητική τιμή, βρίσκοντας τη γραμμική σχέση ανάμεσα σε μία ή περισσότερες μεταβλητές εισόδου και σε μια μεταβλητή εξόδου

Η linear regression έχει :

- Μορφή $Y = f(\theta) + \epsilon$, γραμμικό ως προς παραμέτρους θ
 - y = η προβλεπόμενη τιμή (output)

Το μοντέλο μαθαίνει από τα πρώτα δεδομένα

- Μετά προβλέπει τα επόμενα

Επίσης:

- **Overfitting**
 - Συμβαίνει όταν το μοντέλο προσαρμόζεται υπερβολικά στα δεδομένα εκπαίδευσης
 - Οδηγεί σε κακή γενίκευση σε νέα δεδομένα
 - Η αύξηση των παραμέτρων αυξάνει τον κίνδυνο overfitting
- **Bootstrap**
 - Η μέθοδος που εκτιμά την κατανομή του θορύβου εμπειρικά
 - Χρησιμοποιεί επαναδειγματοληψία των residuals
 - Η εκτίμηση των prediction intervals προκύπτει από τα δεδομένα

Η άσκηση συνολικά

- Στην άσκηση αυτή μελετάμε ένα πραγματικό πρόβλημα από data centers: τη ζήτηση πόρων (GPU) ανά ώρα (τα δεδομένα)
 - Ζητάμε να υλοποιηθεί **forecasting για τις ώρες 1201–1248**, χρησιμοποιώντας ως training set τις πρώτες **1200 ώρες** από το dataset.mat
 - Θα υλοποιηθούν για την άσκηση **δύο μοντέλα πρόβλεψης**:
 - ένα με **linear regression** και
 - ένα με **filters**,Πρέπει να υπολογίζονται και **95% prediction intervals**, να σχεδιαστούν μαζί με τις πραγματικές τιμές και τέλος να συγκριθούν οι δύο μέθοδοι
- Σημείωση για τον κώδικα:** θα πρέπει στην αρχή να φορτωθεί το πακέτο statistics (pkg load statistics)

Μεθοδος 1 : Linear Regression

Ανάλυση πρώτης Μεθόδου για το octave

Εισαγωγή στο Πρόβλημα

- Πραγματικό πρόβλημα από data centers με δεδομένα τη ζήτηση πόρων (GPU) ανά ώρα
- Ο στόχος δεν είναι απλά να μαντέψουμε το μέλλον, αλλά να κατασκευάσουμε ένα μοντέλο που κατανοεί τη συμπεριφορά του συστήματος
- Το forecasting εδώ συνδέεται άμεσα με αποφάσεις:
 - πόσους πόρους να διαθέσουμε
 - πότε περιμένουμε αιχμές
 - πώς αποφεύγουμε bottlenecks

Ανάλυση πρώτης Μεθόδου για το octave

Δομή των Δεδομένων

- Τα δεδομένα είναι χρονική σειρά (time series) με ωριαία δειγματοληψία
- Αυτό σημαίνει ότι αναμένουμε δομές όπως:
 - ημερήσια περιοδικότητα (24 ώρες)
 - εβδομαδιαία περιοδικότητα (168 ώρες)

Προσοχή στο demo οι τιμές T είναι τυχαίες για την περιοδικότητα

- Η αναγνώριση αυτών των patterns είναι κρίσιμη γιατί καθορίζει το μοντέλο που θα χρησιμοποιήσουμε

Ανάλυση πρώτης Μεθόδου για το octave

Διαχωρισμός Train-Test

- Χρησιμοποιούμε τις πρώτες 1200 ώρες για εκπαίδευση και προβλέπουμε τις επόμενες 48 ώρες
- Αυτό είναι σημαντικό γιατί:
 - δεν κάνουμε fitting σε όλα τα δεδομένα
 - αξιολογούμε πραγματική ικανότητα πρόβλεψης

Βασική ιδέα στο Linear Regression

- Στο linear regression προσπαθούμε να περιγράψουμε το σήμα μέσω μιας συνάρτησης

Δηλαδή:

- μοντελοποιούμε τάση με πολυώνυμο
 - μοντελοποιούμε περιοδικότητα με $\sin/\cos$
- Η βασική ιδέα είναι ότι το σήμα αποτελείται από:
 - deterministic μέρος (δομή)
 - stochastic μέρος (θόρυβος)

Ανάλυση πρώτης Μεθόδου για το octave

Ρόλος των Residuals

- Μετά το fitting, αναλύουμε τα residuals (σφάλματα)
- Αν τα residuals (σφάλματα):
 - έχουν pattern → το μοντέλο είναι ανεπαρκές
 - είναι τυχαία → το μοντέλο είναι επαρκές

Prediction & Uncertainty

- Δεν αρκεί να προβλέψουμε μια τιμή
- Πρέπει να δώσουμε και διάστημα πρόβλεψης:
 - βασισμένο στη διασπορά του θορύβου
 - εκφράζει την αβεβαιότητα

Ανάλυση πρώτης Μεθόδου για το octave

- Το regression μοντέλο μας υποθέτει ότι τα δεδομένα αποτελούνται από τρία μέρη:
 - μια μακροχρόνια τάση, επαναλαμβανόμενα μοτίβα και έναν τυχαίο θόρυβο
 - Η τάση μοντελοποιείται με πολυώνυμα, η περιοδικότητα με ημίτονα και συνημίτονα, και ότι απομένει θεωρείται θόρυβος. Στόχος είναι να μάθουμε τα πρώτα δύο και να αγνοήσουμε το θόρυβο για να κάνουμε πρόβλεψη
- Στο regression κομμάτι προσαρμόζουμε ένα μοντέλο της μορφής:
- $Y_t \approx trend(t) + periodic\ terms, Y_i = f_i(\theta) + noise$
- Δηλαδή το μοντέλο προσπαθεί να εξηγήσει τα δεδομένα ως συνδυασμό:
 - πολυωνυμικής τάσης
 - ημιτόνων και συνημιτόνων
 - τυχαίου σφάλματος / θορύβου
- Μετά χρησιμοποιούμε το μοντέλο που μάθαμε από τις πρώτες 1200 ώρες για να προβλέψουμε τις επόμενες 48

Δεδομένα και Ζητούμενα

Dataset

- Χρονική σειρά (ανά ώρα)
- Δεδομένα για GPU requests
- Διάρκεια: ~52 ημέρες
- Θα χρησιμοποιήσετε τις πρώτες 50 ημέρες

Ζητούμενα

- Πρόβλεψη για τις επόμενες 48 ώρες
- Χρήση ιστορικών δεδομένων
- Σύγκριση δύο μεθόδων (Linear , Filters)

Μέθοδος 1: Linear Regression

- Επιλογή features, **Features** = οι μεταβλητές εισόδου (inputs) που χρησιμοποιεί το μοντέλο για να κάνει πρόβλεψη, στη regression:

$$Y = X\beta + \varepsilon, Y \rightarrow \text{αυτό που προβλέπουμε}, X \rightarrow \text{τα features}$$

Προσέχουμε: λίγα features $\rightarrow$ underfitting, πολλά features $\rightarrow$ overfitting

Στο μοντέλο μας επιλέξαμε πολυώνυμο και αρμονικές συνιστώσες συναρτήσεως του χρόνου

Το regression μοντέλο προσπαθεί να μάθει μια συνολική μαθηματική μορφή των δεδομένων: τάση + περιοδικότητα

Μέθοδος 1 - Βοηθητική Σύνοψη Κώδικα 1/3

Προετοιμασία δεδομένων & μοντέλου

- Ο κώδικας φορτώνει το dataset.mat και κρατά τις πρώτες **1200 παρατηρήσεις** ως training set
Ορίζει χρονικό δείκτη $t = 1 \dots 1200$ και κατασκευάζει τον πίνακα X για linear regression
- Περιγράφει τα δεδομένα ως:
τάση + περιοδικότητα + θόρυβος

Μέθοδος 1 - Βοηθητική Σύνοψη Κώδικα 2/3

Εκπαίδευση Linear Regression

- Με την εντολή:

`[b,bint,r,rint,stats] = regress(y(1:nob), X, alpha);`

ο κώδικας υπολογίζει τους συντελεστές b του μοντέλου

- Οι συντελεστές αυτοί δείχνουν πόσο επηρεάζει κάθε όρος την πρόβλεψη:
 - πολυωνυμικοί όροι $\rightarrow$ γενική τάση
 - $\sin/\cos$ όροι $\rightarrow$ περιοδικότητα
 - residuals $r \rightarrow$ σφάλματα του μοντέλου στο training set
- Έπειτα εφαρμόζει το μοντέλο σε όλο το dataset και υπολογίζει τις προβλεπόμενες τιμές

Μέθοδος 1 - Βοηθητική Σύνοψη Κώδικα 3/3

Forecasting, Prediction Intervals & CRPS

- Ο κώδικας συγκρίνει τις προβλέψεις με τις πραγματικές τιμές των ωρών **1201–1248**

Υπολογίζει:

- **MSE (Mean Squared Error)**: μέσο τετραγωνικό σφάλμα στο training set
 - πόσο κοντά είναι οι προβλέψεις στις πραγματικές τιμές, μικρό MSE → καλό μοντέλο
- **95% prediction interval**, δηλαδή με 95% πιθανότητα η πραγματική τιμή να βρίσκεται μέσα σε αυτό το διάστημα
- **CRPS (Continuous Ranked Probability Score)**: μετρική αξιολόγησης πρόβλεψης και αβεβαιότητας (probabilistic forecasts)

Στο forecasting συγκρίνουμε τις προβλέψεις με τις πραγματικές τιμές. Το MSE μετρά το σφάλμα προσαρμογής, τα prediction intervals εκφράζουν την αβεβαιότητα των προβλέψεων, ενώ το CRPS αξιολογεί συνολικά την ποιότητα των probabilistic προβλέψεων, λαμβάνοντας υπόψη τόσο την ακρίβεια όσο και την αβεβαιότητα

Σκελετός που σας δίνεται στον κώδικα

- **Βασική ιδέα** : Το demo μας εκπαιδεύει ένα linear regression μοντέλο που περιγράφει τα δεδομένα ως συνδυασμό τάσης και περιοδικότητας, χρησιμοποιώντας τα πρώτα 1200 σημεία. Στη συνέχεια κάνει πρόβλεψη για τις επόμενες 48 ώρες, υπολογίζει prediction intervals και αξιολογεί το μοντέλο με MSE και CRPS

Το μοντέλο, πιο παραστατικά, προσεγγίζει τα δεδομένα ως:
Τάση (πολυώνυμο) + Περιοδικότητα (sin/cos) + Θόρυβος

- **Υλοποιήθηκαν και σας δίνονται:**
 - Κατασκευή πίνακα X με πολυωνυμικούς και αρμονικούς όρους
 - Εφαρμογή linear regression για εύρεση συντελεστών
 - Υπολογισμός προβλέψεων για όλο το dataset
 - Υπολογισμός MSE (σφάλμα εκπαίδευσης)
 - Κατασκευή prediction intervals (95%)
 - Υπολογισμός CRPS για αξιολόγηση

Filters

Φίλτρα- Filters

- Τα φίλτρα είναι μετασχηματισμοί που εφαρμόζονται σε μια χρονοσειρά για να αφαιρέσουν ή να απομονώσουν συγκεκριμένα χαρακτηριστικά, όπως τάση ή εποχικότητα, ώστε να γίνει πιο εύκολη η ανάλυση και η πρόβλεψη
- Καθαρίζουμε τα δεδομένα από patterns για να τα κάνουμε πιο προβλέψιμα

Ανάλυση δεύτερης Μεθόδου για το octave

FILTERS

- Τα φίλτρα χρησιμοποιούνται για προεπεξεργασία δεδομένων
- Στόχος είναι η αφαίρεση τάσης και εποχικότητας
- Η διαδικασία οδηγεί σε πιο απλά και σταθερά δεδομένα

DIFFERENCING

- Ο τελεστής $\Delta 1$ αφαιρεί το trend/τάση
- Ο τελεστής R_s αφαιρεί την εποχικότητα
- Ο συνδυασμός τους οδηγεί σε stationarity

STATIONARITY

- Stationary σειρά έχει σταθερή μέση τιμή και διασπορά
- Η stationarity είναι βασική προϋπόθεση για πολλά μοντέλα forecasting
- Τα φίλτρα βοηθούν στην επίτευξή της

Ανάλυση δεύτερης Μεθόδου για το octave

BACKSHIFT OPERATOR

- Ο τελεστής B μετατοπίζει τη σειρά στο παρελθόν
- Χρησιμοποιείται για μαθηματική αναπαράσταση φίλτρων
- Επιτρέπει συμπαγή έκφραση διαφορών και φίλτρων

AR, MA, ARMA

- Τα MA (Moving Average) μοντέλα βασίζονται σε προηγούμενα σφάλματα, τα MA είναι FIR (Finite Impulse Response) φίλτρο
- Τα AR (Auto- Regressive) μοντέλα βασίζονται σε προηγούμενες τιμές
- Τα ARMA (Auto- Regressive Moving Average) συνδυάζουν τα δύο, χρησιμοποιούνται στο matlab/octave
- Αποτελούν βασικές δομές για στοχαστική μοντελοποίηση

PREDICTION WITH FILTERS

- Μετά το filtering τα δεδομένα προσεγγίζουν λευκό θόρυβο
- Η πρόβλεψη βασίζεται σε προηγούμενες τιμές της σειράς

Ανάλυση δεύτερης Μεθόδου για το octave

PREDICTION INTERVALS

- Η διασπορά της πρόβλεψης αυξάνεται με τον ορίζοντα πρόβλεψης
- Τα διαστήματα πρόβλεψης γίνονται πιο μεγάλα
- Αυτό αντικατοπτρίζει την αυξανόμενη αβεβαιότητα

Μέθοδος 2 - Βοηθητική Σύνοψη Κώδικα 1/3

Προεπεξεργασία με Filters (Differencing)

- Ο κώδικας παίρνει τα πρώτα **1200 δεδομένα** και εφαρμόζει φίλτρα διαφορών:

$\text{diff}(y) \rightarrow$ αφαιρεί την τάση (trend)

differencing στο lag **T** $\rightarrow$ αφαιρεί περιοδικότητα (seasonality)

συνδυασμός τους $\rightarrow$ πιο “σταθερή” σειρά

$$\Delta_1 \Delta_T Y_t$$

Στόχος: να μετατρέψει τα δεδομένα σε μορφή όπου το μοντέλο είναι πιο απλό και προβλέψιμο

Μέθοδος 2 - Βοηθητική Σύνοψη Κώδικα 2/3

Πρόβλεψη με φίλτρο

- Ο κώδικας χρησιμοποιεί τη σχέση:

$$Y_t = Y_{t-1} + Y_{t-T} - Y_{t-T-1}$$

για να προβλέψει τις επόμενες τιμές

Η ιδέα είναι:

χρησιμοποιούμε προηγούμενες τιμές, εκμεταλλευόμαστε τη δομή της χρονοσειράς, υποθέτουμε ότι ο “θόρυβος” έχει μέση τιμή 0

Έτσι παράγεται η πρόβλεψη yfore

Μέθοδος 2 - Βοηθητική Σύνοψη Κώδικα 3/3

Prediction Intervals & Αξιολόγηση

Ο κώδικας υπολογίζει:

Prediction intervals (95%), που μεγαλώνουν όσο πάμε πιο μακριά στο μέλλον

Αυτό γίνεται μέσω του inverse filter και της διασποράς των residuals

Στο τέλος:

συγκρίνει πραγματικές τιμές vs προβλέψεις

υπολογίζει **CRPS** για αξιολόγηση

ΔΙΑΓΩΝΙΣΜΟΣ - ΠΡΟΑΙΡΕΤΙΚΟ

- Στον διαγωνισμό θα προβλέψετε τις τιμές μιας χρονοσειράς για τις επόμενες 256 ώρες, χρησιμοποιώντας τα πρώτα 1248 δεδομένα ως training set
- Εδώ δεν μας ενδιαφέρει μόνο η ακρίβεια της πρόβλεψης, αλλά και η σωστή εκτίμηση της αβεβαιότητας, καθώς αξιολογούμαστε με τη μετρική CRPS
- Θα εφαρμόσετε δύο διαφορετικές προσεγγίσεις μόνες τους ή συνδυαστικά:
 - linear regression, που μοντελοποιεί τα δεδομένα ως συνδυασμό τάσης και περιοδικότητας, και
 - filters, που αφαιρούν trend και seasonality πριν την πρόβλεψη
- Στο τέλος θα συγκρίνετε τα μοντέλα με βάση τις προβλέψεις και τα prediction intervals και επιλέγουμε αυτό που επιτυγχάνει την καλύτερη ισορροπία μεταξύ ακρίβειας και αβεβαιότητας