

ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

Τομέας Επικοινωνιών, Ηλεκτρονικής και Συστημάτων Πληροφορικής
Εργαστήριο Διαχείρισης και Βέλτιστου Σχεδιασμού Δικτύων Τηλεματικής - NETMODE

Συστήματα Αναμονής
6^η Εργαστηριακή Άσκηση



Στοιχεία Φοιτητή

- Όνομα: Πέππας Μιχαήλ-Αθανάσιος
- Αριθμός Μητρώου: 03121026
- 4^η Εργαστηριακή Ομάδα (Δευτέρα, 12:45-14:30)
- Ημερομηνία Διεξαγωγής Εργαστηρίου: 04.05.2026
- Ημερομηνία Παράδοσης Αναφοράς: 17.06.2026

Περιεχόμενα

1	Πρόβλεψη χρονοσειράς φόρτου	4
1.1	Στόχος της άσκησης	4
1.2	Περιγραφή των δεδομένων	4
2	Θεωρητικό υπόβαθρο	6
2.1	Η έννοια της πρόβλεψης	6
2.2	Γραμμική παλινδρόμηση για πρόβλεψη	6
2.3	Φίλτρα και διαφοροποίηση χρονοσειράς	7
2.4	Μετρικές αξιολόγησης	8
3	Μεθοδολογία μοντελοποίησης	9
3.1	Επιλογή υποψήφιων μοντέλων	9
4	Αποτελέσματα γραμμικής παλινδρόμησης	10
4.1	Σύγκριση υποψήφιων μοντέλων	10
4.2	Γραφική απεικόνιση του καλύτερου regression μοντέλου	11
5	Αποτελέσματα φίλτρων	12
5.1	Σύγκριση υποψήφιων φίλτρων	12
5.2	Διαγνωστικά residuals του καλύτερου φίλτρου	13
5.3	Πρόβλεψη με το καλύτερο φίλτρο	14
6	Τελική σύγκριση επιλεγμένων μοντέλων	14
6.1	Αριθμητική σύγκριση	14
6.2	Κοινή γραφική σύγκριση με διαστήματα πρόβλεψης	15
6.3	Σύγκριση σημειακών προβλέψεων	16
6.4	Έξοδος του προγράμματος σε Octave	17
7	Συνολικό συμπέρασμα	18

8	Παράρτημα Υλοποίησης σε Octave	20
8.1	Κώδικας Υλοποίησης	20
8.2	Έξοδος Προγράμματος	34

1 Πρόβλεψη χρονοσειράς φόρτου

1.1 Στόχος της άσκησης

Στην παρούσα εργαστηριακή άσκηση μελετάμε το πρόβλημα της πρόβλεψης χρονοσειράς, με εφαρμογή σε δεδομένα ζήτησης υπολογιστικών πόρων GPU. Η λογική του προβλήματος συνδέεται άμεσα με τη σχεδίαση και αξιολόγηση συστημάτων αναμονής: πριν διαστασιολογηθεί ένα σύστημα, πρέπει να υπάρχει εκτίμηση όχι μόνο της φύσης του φόρτου, αλλά και της έντασής του στο μέλλον. Η πρόβλεψη φόρτου είναι επομένως απαραίτητη για capacity planning, επιλογή πόρων, αποφυγή συμφόρησης και αποφυγή υπερβολικής υπερδιαστασιολόγησης.

Το αρχείο δεδομένων περιέχει μία χρονοσειρά ωριαίων παρατηρήσεων. Σύμφωνα με την εκφώνηση, χρησιμοποιούμε τις πρώτες 1200 ώρες ως ιστορικά δεδομένα εκπαίδευσης και προβλέπουμε τις αμέσως επόμενες ώρες. Στο συγκεκριμένο αρχείο `dataset.mat` που χρησιμοποιήθηκε στην εκτέλεση υπήρχαν συνολικά 1247 παρατηρήσεις, άρα ο τελικός ορίζοντας πρόβλεψης ήταν οι ώρες 1201 έως 1247, δηλαδή 47 μελλοντικές τιμές.

Το βασικό μέρος της άσκησης απαιτεί την εφαρμογή και σύγκριση δύο κατηγοριών μεθόδων:

- μοντέλα γραμμικής παλινδρόμησης,
- μοντέλα πρόβλεψης με φίλτρα.


Το προαιρετικό μέρος της άσκησης, δηλαδή ο διαγωνισμός, δεν υλοποιήθηκε. Η παρούσα αναφορά αφορά μόνο το βασικό μέρος.

1.2 Περιγραφή των δεδομένων

Η χρονοσειρά συμβολίζεται με Y_t , όπου t είναι ο διακριτός χρόνος σε ώρες. Τα δεδομένα χωρίστηκαν ως εξής:

Τμήμα δεδομένων	Ώρες	Πλήθος παρατηρήσεων
Training set	1, ..., 1200	1200
Forecast/Test set	1201, ..., 1247	47
Σύνολο	1, ..., 1247	1247

Στο Σχήμα 1 φαίνεται η συνολική χρονοσειρά και το σημείο διαχωρισμού μεταξύ ιστορικών και μελλοντικών τιμών.



Σχήμα 1: Δεδομένα χρονοσειράς και διαχωρισμός training/test.

Παρατηρούμε ότι η χρονοσειρά παρουσιάζει έντονη μεταβλητότητα και ορισμένες μεγάλες αιχμές. Οι αιχμές αυτές είναι σημαντικές, επειδή δεν αποτελούν ομαλές περιοδικές συνιστώσες και επομένως δεν αναμένεται να προβλεφθούν με ακρίβεια από απλά ντιτερμινιστικά μοντέλα. Αντίθετα, τα μοντέλα μπορούν κυρίως να συλλάβουν τη μέση δομή, την τάση και την εποχικότητα της σειράς.

2 Θεωρητικό υπόβαθρο

2.1 Η έννοια της πρόβλεψης

Στη θεωρία πρόβλεψης χρονοσειρών, αν έχουν παρατηρηθεί οι τιμές:

$$Y_1, Y_2, \dots, Y_t,$$

τότε η πλήρης πρόβλεψη για μια μελλοντική τιμή $Y_{t+\ell}$ είναι η υπό συνθήκη κατανομή:

$$P(Y_{t+\ell} \mid Y_1, \dots, Y_t).$$

Η σημειακή πρόβλεψη είναι συνήθως η υπό συνθήκη μέση τιμή:

$$\hat{Y}_{t+\ell} = E(Y_{t+\ell} \mid Y_1, \dots, Y_t).$$

Ωστόσο, στην πράξη δεν αρκεί μόνο μία σημειακή πρόβλεψη. Επειδή η μελλοντική τιμή είναι τυχαία και δεν μπορεί να προβλεφθεί χωρίς σφάλμα, πρέπει να συνοδεύεται από διάστημα πρόβλεψης. Για επίπεδο εμπιστοσύνης 95%, ένα prediction interval έχει γενικά τη μορφή:

$$[\hat{Y}_{t+\ell} - c_\ell, \hat{Y}_{t+\ell} + c_\ell],$$

όπου το c_ℓ εκφράζει την αβεβαιότητα της πρόβλεψης στον ορίζοντα ℓ .

Είναι σημαντικό να τονιστεί ότι τα prediction intervals δεν είναι ίδια με τα confidence intervals της μέσης τιμής. Τα prediction intervals αφορούν μελλοντικές πραγματικές παρατηρήσεις και επομένως είναι συνήθως ευρύτερα.

2.2 Γραμμική παλινδρόμηση για πρόβλεψη

Στη γραμμική παλινδρόμηση θεωρούμε ότι η χρονοσειρά γράφεται ως:

$$Y_t = f_t(\beta) + \epsilon_t,$$

όπου $f_t(\beta)$ είναι γνωστή συνάρτηση ως προς τον χρόνο και γραμμική ως προς το διάνυσμα παραμέτρων β , ενώ ϵ_t είναι ο τυχαίος όρος σφάλματος.

Στην παρούσα άσκηση χρησιμοποιήθηκαν όροι τάσης και περιοδικότητας. Για την περιοδικότητα χρησιμοποιήθηκαν ημιτονοειδείς και συνημιτονοειδείς όροι:

$$\cos\left(\frac{2\pi t}{T}\right), \quad \sin\left(\frac{2\pi t}{T}\right),$$

όπου T είναι η περίοδος σε ώρες.

Επειδή τα δεδομένα είναι ωριαία, οι φυσικές περίοδοι που εξετάζονται είναι:

$$T = 24$$

για ημερήσια περιοδικότητα, και:

$$T = 168 = 7 \cdot 24$$

για εβδομαδιαία περιοδικότητα.

Για παράδειγμα, το μοντέλο που τελικά επιλέχθηκε στην κατηγορία της παλινδρόμησης έχει μορφή:

$$Y_t = \beta_0 + \beta_1 t + \beta_2 \cos\left(\frac{2\pi t}{24}\right) + \beta_3 \sin\left(\frac{2\pi t}{24}\right) + \beta_4 \cos\left(\frac{2\pi t}{168}\right) + \beta_5 \sin\left(\frac{2\pi t}{168}\right) + \epsilon_t.$$

Η εκτίμηση των παραμέτρων γίνεται με τη μέθοδο των ελαχίστων τετραγώνων. Αν θεωρήσουμε ότι τα σφάλματα είναι ανεξάρτητα, κανονικά και με σταθερή διασπορά, τότε η μέθοδος ελαχίστων τετραγώνων αντιστοιχεί και σε εκτίμηση μέγιστης πιθανοφάνειας.

2.3 Φίλτρα και διαφοροποίηση χρονοσειράς

Η δεύτερη οικογένεια μεθόδων βασίζεται στη χρήση φίλτρων. Ένα φίλτρο εφαρμόζεται στη χρονοσειρά ώστε να αφαιρέσει συστηματικές συνιστώσες, όπως τάση ή εποχικότητα, και να μετατρέψει το υπόλοιπο σε πιο απλή διαδικασία προς πρόβλεψη.

Χρησιμοποιούμε τον τελεστή οπισθοδρόμησης B , με:

$$BY_t = Y_{t-1}.$$

Ο τελεστής διαφοροποίησης τάξης s είναι:

$$\Delta_s = 1 - B^s.$$

Άρα:

$$\Delta_s Y_t = Y_t - Y_{t-s}.$$

Για ημερήσια εποχικότητα χρησιμοποιείται:

$$\Delta_{24} Y_t = Y_t - Y_{t-24},$$

ενώ για εβδομαδιαία εποχικότητα:

$$\Delta_{168}Y_t = Y_t - Y_{t-168}.$$

Γενικά, αν το φίλτρο είναι:

$$F(B)Y_t = c + \epsilon_t,$$

τότε η πρόβλεψη γίνεται αντιστρέφοντας το φίλτρο. Στην υλοποίηση, το c εκτιμήθηκε ως ο εμπειρικός μέσος της φιλτραρισμένης σειράς στο training set. Αν ο μέσος αυτός είναι κοντά στο μηδέν, τότε το μοντέλο ανάγεται στην κλασική υπόθεση ότι η φιλτραρισμένη σειρά είναι θόρυβος μηδενικής μέσης τιμής.

2.4 Μετρικές αξιολόγησης

Για τη σύγκριση των μοντέλων χρησιμοποιήθηκαν οι εξής μετρικές:

- Mean Absolute Error:

$$MAE = \frac{1}{m} \sum_{i=1}^m |Y_i - \hat{Y}_i|.$$

- Root Mean Squared Error:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (Y_i - \hat{Y}_i)^2}.$$

- Coverage των 95% prediction intervals:

$$Coverage = \frac{\#\{Y_i \in [L_i, U_i]\}}{m}.$$

- Median CRPS.

Το CRPS χρησιμοποιήθηκε ως βασικό κριτήριο επιλογής του καλύτερου μοντέλου ανά κατηγορία, επειδή αξιολογεί ταυτόχρονα τη θέση της προβλεπτικής κατανομής και το εύρος της αβεβαιότητας. Για κανονική προβλεπτική κατανομή με μέση τιμή μ και τυπική απόκλιση σ , το CRPS υπολογίζεται από:

$$CRPS = \sigma \left[a(2\Phi(a) - 1) + 2\phi(a) - \frac{1}{\sqrt{\pi}} \right],$$

όπου:

$$a = \frac{y - \mu}{\sigma}.$$

Εδώ Φ και ϕ είναι αντίστοιχα η αθροιστική συνάρτηση κατανομής και η πυκνότητα της τυπικής κανονικής κατανομής.

3 Μεθοδολογία μοντελοποίησης

3.1 Επιλογή υποψήφιων μοντέλων

Για να μην βασιστούμε σε ένα αυθαίρετα επιλεγμένο μοντέλο, δοκιμάστηκαν πέντε παραλλαγές για κάθε κατηγορία μεθόδων. Δεν χρησιμοποιήθηκε ξεχωριστό validation set, επειδή η εκφώνηση ζητά να χρησιμοποιηθούν οι πρώτες 1200 ώρες ως ιστορικό και να προβλεφθούν οι επόμενες ώρες. Έτσι, όλα τα μοντέλα προσαρμόστηκαν στο ίδιο training set και αξιολογήθηκαν στο ζητούμενο forecast/test interval.

Τα πέντε υποψήφια μοντέλα γραμμικής παλινδρόμησης ήταν:

Μοντέλο	Περιγραφή	Λογική
LR1	Σταθερός όρος + ημερήσια περιοδικότητα $T = 24$	Βασικό ημερήσιο μοντέλο
LR2	Γραμμική τάση + ημερήσια περιοδικότητα $T = 24$	Προσθήκη αργής μεταβολής
LR3	Γραμμική τάση + ημερήσια $T = 24$ + εβδομαδιαία $T = 168$ περιοδικότητα	Ημερήσια και εβδομαδιαία δομή
LR4	Τετραγωνική τάση + ημερήσια $T = 24$ + εβδομαδιαία $T = 168$ περιοδικότητα	Έλεγχος καμπυλότητας
LR5	Γραμμική τάση + περίοδοι 24, 12, 168	Πρόσθετη ημihμερήσια αρμονική

Τα πέντε υποψήφια μοντέλα φίλτρων ήταν:

Μοντέλο	Φίλτρο	Λογική
F1	Δ_{24}	Αφαίρεση ημερήσιας εποχικότητας
F2	$\Delta_1 \Delta_{24}$	Αφαίρεση τάσης και ημερήσιας εποχικότητας
F3	Δ_{168}	Αφαίρεση εβδομαδιαίας εποχικότητας
F4	$\Delta_1 \Delta_{168}$	Αφαίρεση τάσης και εβδομαδιαίας εποχικότητας
F5	$\Delta_{24} \Delta_{168}$	Συνδυασμός ημερήσιας και εβδομαδιαίας διαφοροποίησης

Η επιλογή του καλύτερου μοντέλου σε κάθε κατηγορία έγινε με βάση το μικρότερο median CRPS. Η επιλογή αυτή είναι κατάλληλη, επειδή δεν ενδιαφέρει μόνο το μέσο τετραγωνικό σφάλμα της σημειακής πρόβλεψης, αλλά και το αν τα prediction intervals είναι χρήσιμα και όχι υπερβολικά στενά ή υπερβολικά πλατιά.

4 Αποτελέσματα γραμμικής παλινδρόμησης

4.1 Σύγκριση υποψήφιων μοντέλων

Τα αποτελέσματα των πέντε μοντέλων παλινδρόμησης φαίνονται στον Πίνακα 1.

Πίνακας 1: Αποτελέσματα υποψήφιων μοντέλων γραμμικής παλινδρόμησης.

Μοντέλο	Παράμ.	Train MSE	MAE	RMSE	Median CRPS
LR1: constant + daily 24	3	521883.168	538.035	791.283	260.300
LR2: linear trend + daily 24	4	513540.892	458.657	710.656	232.094
LR3: linear trend + daily 24 + weekly 168	6	498776.282	419.878	675.712	209.130
LR4: quadratic trend + daily 24 + weekly 168	7	497531.338	437.483	702.799	215.583
LR5: linear trend + daily 24 + half-daily 12 + weekly 168	8	490046.575	402.893	644.796	235.488

Το καλύτερο μοντέλο με βάση το median CRPS είναι το:

LR3 : linear trend + daily 24 + weekly 168.


Παρατηρούμε ότι το *LR5* έχει μικρότερο *MAE* και *RMSE* από το *LR3*, όμως έχει χειρότερο median CRPS. Αυτό σημαίνει ότι, παρότι οι σημειακές προβλέψεις του *LR5* είναι

ελαφρώς καλύτερες ως προς τα απόλυτα και τετραγωνικά σφάλματα, η συνολική πιθανοτική πρόβλεψη, δηλαδή ο συνδυασμός σημειακής πρόβλεψης και αβεβαιότητας, είναι καλύτερη για το *LR3*.

Η παρατήρηση αυτή είναι σημαντική σε σχέση με το overfitting. Το *LR5* έχει περισσότερες παραμέτρους και μικρότερο training MSE, αλλά αυτό δεν μεταφράζεται σε καλύτερο probabilistic forecast. Αντίθετα, το *LR3* αποτελεί πιο ισορροπημένη επιλογή, επειδή περιέχει τις δύο βασικές εποχικότητες χωρίς να προσθέτει υπερβολική πολυπλοκότητα.

4.2 Γραφική απεικόνιση του καλύτερου regression μοντέλου

Στο Σχήμα 2 φαίνεται η προσαρμογή του καλύτερου μοντέλου παλινδρόμησης στο training set.




Σχήμα 2: Προσαρμογή του καλύτερου regression μοντέλου στο training set.

Το μοντέλο δεν προσπαθεί να ακολουθήσει όλες τις αιχμές της χρονοσειράς, κάτι που θα οδηγούσε σε υπερπροσαρμογή. Αντίθετα, συλλαμβάνει τη βασική περιοδική δομή και τη μέση μεταβολή του σήματος. Αυτό είναι επιθυμητό, επειδή οι απότομες αιχμές αποτελούν κυρίως τυχαίες διακυμάνσεις ή έκτακτα γεγονότα και δεν είναι εύκολο να προβλεφθούν από ένα απλό regression μοντέλο.

Στο Σχήμα 3 φαίνεται η πρόβλεψη του *LR3* στο test interval μαζί με τα 95% prediction

intervals.



Σχήμα 3: Πρόβλεψη του καλύτερου regression μοντέλου με 95% prediction intervals.

Τα prediction intervals καλύπτουν σχεδόν όλες τις πραγματικές τιμές. Η τελική κάλυψη είναι 97.87%, ελαφρώς υψηλότερη από το ονομαστικό 95%. Αυτό δείχνει ότι τα διαστήματα είναι λίγο συντηρητικά, αλλά παραμένουν χρήσιμα. Η μεγάλη αιχμή κοντά στην ώρα 1239 δεν προβλέπεται σημειακά και βρίσκεται εκτός του διαστήματος πρόβλεψης. Αυτό είναι φυσιολογικό: ένα τέτοιο spike είναι δύσκολο να προβλεφθεί από deterministic terms, αλλά μπορεί να καλυφθεί από την εκτιμημένη αβεβαιότητα, αν και όταν αυτό γίνει υπερβολικά μεγάλο, τότε είναι αναμενόμενο να ξεφύγει από τα προδιαγεγραμμένα διαστήματα πρόβλεψης.

5 Αποτελέσματα φίλτρων

5.1 Σύγκριση υποψήφιων φίλτρων

Τα αποτελέσματα των πέντε φίλτρων φαίνονται στον Πίνακα 2.

Το καλύτερο φίλτρο με βάση το median CRPS είναι:

$$F3 : \Delta_{168}.$$

Πίνακας 2: Αποτελέσματα υποψήφιων μοντέλων φίλτρων.

Μοντέλο	Τάξη	Residual Std	MAE	RMSE	Median CRPS
F1: Δ_{24}	24	904.672	475.487	734.967	310.531
F2: $\Delta_1\Delta_{24}$	25	1110.336	753.587	1043.372	1338.159
F3: Δ_{168}	168	955.139	616.918	864.900	296.036
F4: $\Delta_1\Delta_{168}$	169	1176.400	970.518	1219.322	1402.320
F5: $\Delta_{24}\Delta_{168}$	192	1267.724	832.639	1308.248	456.351

Δηλαδή, το καλύτερο φίλτρο είναι η εβδομαδιαία διαφοροποίηση:

$$\Delta_{168}Y_t = Y_t - Y_{t-168}.$$

Αξίζει να σημειωθεί ότι το $F1 = \Delta_{24}$ έχει καλύτερο MAE και $RMSE$ από το $F3$, αλλά χειρότερο median CRPS. Επομένως, αν εξετάζαμε μόνο τις σημειακές προβλέψεις, το ημερήσιο φίλτρο θα ήταν ισχυρότερος υποψήφιος. Όμως, επειδή στην άσκηση ζητούνται και prediction intervals, το CRPS είναι πιο ολοκληρωμένο κριτήριο. Με βάση αυτό, το εβδομαδιαίο φίλτρο δίνει καλύτερη συνολική πιθανοτική πρόβλεψη.

Τα φίλτρα που περιλαμβάνουν επιπλέον Δ_1 έχουν σαφώς χειρότερη επίδοση. Αυτό δείχνει ότι η πρώτη διαφοροποίηση πιθανότατα οδηγεί σε over-differencing. Με άλλα λόγια, αφαιρεί περισσότερη δομή από όση χρειάζεται, αυξάνει τη μεταβλητότητα των residuals και τελικά οδηγεί σε χειρότερες προβλέψεις και ευρύτερα ή λιγότερο αποδοτικά prediction intervals.


5.2 Διαγνωστικά residuals του καλύτερου φίλτρου

Στο Σχήμα 4 φαίνονται τα κεντραρισμένα residuals του φίλτρου Δ_{168} .

Η φιλτραρισμένη σειρά κινείται γενικά γύρω από το μηδέν, κάτι που είναι επιθυμητό για ένα μοντέλο της μορφής:

$$F(B)Y_t = c + \epsilon_t.$$

Ωστόσο, παραμένουν έντονες αιχμές. Οι αιχμές αυτές δείχνουν ότι η χρονοσειρά δεν μπορεί να περιγραφεί πλήρως από ένα απλό εποχικό φίλτρο. Παρόλα αυτά, το φίλτρο Δ_{168} καταφέρνει να εκμεταλλευτεί την εβδομαδιαία επανάληψη του φορτίου και να δώσει την καλύτερη πιθανοτική επίδοση μεταξύ των φίλτρων.



Σχήμα 4: Κεντραρισμένα residuals του καλύτερου φίλτρου $F3 = \Delta_{168}$.

5.3 Πρόβλεψη με το καλύτερο φίλτρο

Στο Σχήμα 5 φαίνεται η πρόβλεψη του καλύτερου φίλτρου στο test interval.

Το φίλτρο ακολουθεί πιο απότομα τις τιμές της προηγούμενης εβδομάδας και γι' αυτό παρουσιάζει πιο έντονη τοπική μεταβλητότητα από το regression. Τα prediction intervals είναι αρκετά πλατιά ώστε να καλύπτουν τις περισσότερες πραγματικές τιμές, με τελική κάλυψη 97.87%. Το εύρος αυτό είναι αναμενόμενο, επειδή στα φίλτρα η αβεβαιότητα διαδίδεται μέσω της αντίστροφης αναπαράστασης του φίλτρου.


6 Τελική σύγκριση επιλεγμένων μοντέλων

6.1 Αριθμητική σύγκριση

Στον Πίνακα 3 συγκρίνονται τα δύο τελικά επιλεγμένα μοντέλα, δηλαδή το καλύτερο regression και το καλύτερο filter.

Πίνακας 3: Τελική σύγκριση επιλεγμένων μοντέλων.

Επιλεγμένο μοντέλο	MAE	RMSE	Coverage	Median CRPS
LR3: linear trend + daily 24 + weekly 168	419.878	675.712	97.87%	209.130
F3: Δ_{168}	616.918	864.900	97.87%	296.036



Σχήμα 5: Πρόβλεψη του καλύτερου φίλτρου $F3 = \Delta_{168}$ με 95% prediction intervals.


Το regression μοντέλο $LR3$ υπερέχει σε όλες τις βασικές μετρικές σφάλματος και στο median CRPS, ενώ έχει την ίδια κάλυψη prediction interval με το καλύτερο φίλτρο. Συνεπώς, αποτελεί την καλύτερη συνολική επιλογή για τα συγκεκριμένα δεδομένα και τον συγκεκριμένο ορίζοντα πρόβλεψης.

Η ίση κάλυψη 97.87% δείχνει ότι και τα δύο μοντέλα δίνουν επαρκώς συντηρητικά 95% intervals. Όμως, το regression έχει χαμηλότερο CRPS, άρα πετυχαίνει καλύτερο συμβιβασμό μεταξύ ακρίβειας σημειακής πρόβλεψης και εύρους αβεβαιότητας.

6.2 Κοινή γραφική σύγκριση με διαστήματα πρόβλεψης

Στο Σχήμα 6 παρουσιάζεται η κοινή γραφική σύγκριση των δύο τελικά επιλεγμένων μοντέλων. Στο ίδιο διάγραμμα φαίνονται οι πραγματικές τιμές του forecast interval, οι σημειακές προβλέψεις της γραμμικής παλινδρόμησης και του φίλτρου, καθώς και τα αντίστοιχα 95% prediction intervals.

Το διάγραμμα επιβεβαιώνει οπτικά τα αριθμητικά αποτελέσματα του Πίνακα 3. Το regression μοντέλο δίνει πιο ομαλή πρόβλεψη και στενότερη περιοδική δομή, ενώ το filter μοντέλο εμφανίζει εντονότερες τοπικές διακυμάνσεις, επειδή βασίζεται στην εβδομαδιαία υστέρηση. Και τα δύο μοντέλα παρέχουν επαρκή κάλυψη των πραγματικών τιμών, όμως



Σχήμα 6: Κοινή σύγκριση των επιλεγμένων μοντέλων με 95% prediction intervals.

το regression μοντέλο επιτυγχάνει καλύτερο συνολικό συμβιβασμό μεταξύ ακρίβειας και αβεβαιότητας, όπως φαίνεται από το μικρότερο median CRPS.


6.3 Σύγκριση σημειακών προβλέψεων

Στο Σχήμα 7 φαίνονται οι σημειακές προβλέψεις των δύο επιλεγμένων μοντέλων σε σχέση με τις πραγματικές τιμές.


Η παλινδρόμηση δίνει πιο ομαλή πρόβλεψη, επειδή βασίζεται σε deterministic αρμονικούς όρους. Αντίθετα, το φίλτρο δίνει πιο ευμετάβλητη πρόβλεψη, επειδή ουσιαστικά αξιοποιεί παρελθοντικές τιμές με βάση την εβδομαδιαία υστέρηση. Η ομαλή συμπεριφορά του regression αποδεικνύεται πιο κατάλληλη στο συγκεκριμένο forecast interval, επειδή μειώνει το μέσο σφάλμα χωρίς να χάνει τη βασική περιοδική δομή.

Στο Σχήμα 8 παρουσιάζεται η σύγκριση των απόλυτων σφαλμάτων.

Και τα δύο μοντέλα αποτυγχάνουν να προβλέψουν σημειακά τη μεγάλη αιχμή κοντά στην ώρα 1239. Αυτό είναι αναμενόμενο, γιατί τέτοιες ακραίες τιμές δεν εξηγούνται εύκολα από απλή εποχικότητα ή γραμμική τάση. Ωστόσο, εκτός από αυτήν την αιχμή, το regression παρουσιάζει γενικά μικρότερα σφάλματα από το φίλτρο, κάτι που συμφωνεί με τα συνολικά *MAE* και *RMSE*.



Σχήμα 7: Σύγκριση σημειακών προβλέψεων των επιλεγμένων μοντέλων.



Σχήμα 8: Σύγκριση απόλυτου σφάλματος των επιλεγμένων μοντέλων.

6.4 Έξοδος του προγράμματος σε Octave

Παρακάτω παρατίθεται η βασική έξοδος του προγράμματος από το Octave.

```
=====
Lab 6 - Basic Forecasting with Model Selection
=====

Loaded dataset: dataset.mat
Number of observations: 1247
```

Training observations: 1200
Forecast observations: 47
Forecast horizon: 1201 to 1247
Confidence level: 95%

Linear Regression Candidate Models

Model	Params	Train MSE	MAE	RMSE	Med CRPS
LR1: constant + daily 24	3	521883.168	538.035	791.283	260.300
LR2: linear trend + daily 24	4	513540.892	458.657	710.656	232.094
LR3: linear trend + daily 24 + weekly 168	6	498776.282	419.878	675.712	209.130
LR4: quadratic trend + daily 24 + weekly 168	7	497531.338	437.483	702.799	215.583
LR5: linear trend + daily 24 + half-daily 12 + weekly 168	8	490046.575	402.893	644.796	235.488

Best Linear Regression model by median CRPS:

LR3: linear trend + daily 24 + weekly 168

Filter Candidate Models

Model	Order	Res Std	MAE	RMSE	Med CRPS
F1: Delta_24	24	904.672	475.487	734.967	310.531
F2: Delta_1 Delta_24	25	1110.336	753.587	1043.372	1338.159
F3: Delta_168	168	955.139	616.918	864.900	296.036
F4: Delta_1 Delta_168	169	1176.400	970.518	1219.322	1402.320
F5: Delta_24 Delta_168	192	1267.724	832.639	1308.248	456.351

Best Filter model by median CRPS:

F3: Delta_168

Final Selected Models Comparison

Selected model	MAE	RMSE	Coverage	Med CRPS
LR3: linear trend + daily 24 + weekly 168	419.878	675.712	97.87%	209.130
F3: Delta_168	616.918	864.900	97.87%	296.036

Overall, the selected Linear Regression model has better median CRPS.

Saved figures as PNG files in the current directory.

Saved model comparison metrics to lab6_model_comparison_results.csv.

Execution completed successfully.

7 Συνολικό συμπέρασμα

Στην παρούσα άσκηση εφαρμόστηκαν δύο βασικές κατηγορίες μεθόδων πρόβλεψης χρονοσειρών: γραμμική παλινδρόμηση και φίλτρα διαφοροποίησης. Για κάθε κατηγορία δο-

κινιάστηκαν πέντε θεωρητικά αιτιολογημένες παραλλαγές, ώστε η τελική επιλογή να μη βασιστεί σε ένα αυθαίρετο μοντέλο.

Στην κατηγορία της γραμμικής παλινδρόμησης, το καλύτερο μοντέλο ήταν το $LR3$, το οποίο περιλαμβάνει γραμμική τάση, ημερήσια περιοδικότητα 24 ωρών και εβδομαδιαία περιοδικότητα 168 ωρών. Η επιλογή αυτή είναι συνεπής με τη φύση των δεδομένων, αφού σε ωριαίες χρονοσειρές φόρτου είναι αναμενόμενο να εμφανίζονται ημερήσια και εβδομαδιαία πρότυπα.

Στην κατηγορία των φίλτρων, το καλύτερο μοντέλο ήταν το $F3 = \Delta_{168}$, δηλαδή το φίλτρο εβδομαδιαίας διαφοροποίησης. Το αποτέλεσμα αυτό δείχνει ότι η εβδομαδιαία επανάληψη είναι σημαντική στη συγκεκριμένη χρονοσειρά. Τα φίλτρα που περιλάμβαναν επιπλέον πρώτη διαφοροποίηση είχαν χειρότερη συμπεριφορά, κάτι που υποδηλώνει ότι η επιπλέον διαφοροποίηση οδηγεί σε over-differencing.

Η τελική σύγκριση έδειξε ότι το regression μοντέλο $LR3$ υπερέχει του καλύτερου φίλτρου $F3$. Συγκεκριμένα, πέτυχε μικρότερο MAE , μικρότερο $RMSE$ και μικρότερο median CRPS, ενώ είχε την ίδια κάλυψη των 95% prediction intervals. Επομένως, για τα συγκεκριμένα δεδομένα και τον συγκεκριμένο forecast horizon, η γραμμική παλινδρόμηση με ημερήσια και εβδομαδιαία εποχικότητα αποτελεί την καλύτερη από τις εξεταζόμενες επιλογές.

Τέλος, τα αποτελέσματα αναδεικνύουν και ένα γενικό συμπέρασμα για την πρόβλεψη φόρτου σε συστήματα αναμονής: οι ομαλές περιοδικές συνιστώσες μπορούν να προβλεφθούν ικανοποιητικά, όμως οι απότομες αιχμές παραμένουν δύσκολες. Για τον λόγο αυτό, η χρήση prediction intervals είναι απαραίτητη, επειδή εκφράζει την αβεβαιότητα που δεν μπορεί να αποτυπωθεί από τη σημειακή πρόβλεψη.

8 Παράρτημα Υλοποίησης σε Octave

8.1 Κώδικας Υλοποίησης

lab6

```
1  function lab6()
2  % =====
3  % File: lab6.m
4  % Course: Queueing Systems - Lab 6
5  % Topic: Time-Series Forecasting
6  %
7  % Basic part only - no validation set:
8  %   1. Try 5 Linear Regression models
9  %   2. Try 5 Filter models
10 %   3. Select the best model in each category using median CRPS
11 %   4. Plot only:
12 %       - best Linear Regression model
13 %       - best Filter model
14 %       - comparison between the two selected models
15 %
16 % Required file:
17 %   dataset.mat must be in the same directory as this .m file.
18 % =====
19
20 close all;
21 clc;
22
23 % Octave needs the statistics package for norminv, normcdf, normpdf.
24 if exist('pkg', 'builtin') || exist('pkg', 'file')
25     try
26         pkg load statistics;
27     catch
28         warning('Could not load Octave statistics package. Make sure norminv, normcdf and
29 normpdf are available.');
```

end

```
30 end
31
32 % =====
33 % 1. Load dataset
34 % =====
35
36 dataset_file = 'dataset.mat';
37
38 data = load(dataset_file);
39
40 if ~isfield(data, 'values')
41     error('dataset.mat does not contain a variable named values.');
```

end

```
42
43
44 y = double(data.values(:));
45
46 n = length(y);
47 nob = 1200; % first 50 days = 1200 hours
48 alpha = 0.05; % 95% prediction interval
49 z = norminv(1 - alpha / 2); % approximately 1.96
```

```

50
51 if n <= nob
52     error('The dataset must contain more than 1200 observations.');
```

end

```

54
55 nforecast = n - nob;
56 t_all = (1:n)';
57 forecast_idx = (nob + 1:n)';
58
59 fprintf('\n===== \n');
60 fprintf('Lab 6 - Basic Forecasting with Model Selection\n');
61 fprintf('===== \n');
62 fprintf('Loaded dataset: %s\n', dataset_file);
63 fprintf('Number of observations: %d\n', n);
64 fprintf('Training observations: %d\n', nob);
65 fprintf('Forecast observations: %d\n', nforecast);
66 fprintf('Forecast horizon: %d to %d\n', nob + 1, n);
67 fprintf('Confidence level: 95%\n');
```

=====

```

69 %
70 % 2. Evaluate 5 Linear Regression models
71 %
72
73 reg_results(1) = evaluate_regression_model(y, nob, alpha, ...
74     'LR1: constant + daily 24', ...
75     0, [24]);
76
77 reg_results(2) = evaluate_regression_model(y, nob, alpha, ...
78     'LR2: linear trend + daily 24', ...
79     1, [24]);
80
81 reg_results(3) = evaluate_regression_model(y, nob, alpha, ...
82     'LR3: linear trend + daily 24 + weekly 168', ...
83     1, [24, 168]);
84
85 reg_results(4) = evaluate_regression_model(y, nob, alpha, ...
86     'LR4: quadratic trend + daily 24 + weekly 168', ...
87     2, [24, 168]);
88
89 reg_results(5) = evaluate_regression_model(y, nob, alpha, ...
90     'LR5: linear trend + daily 24 + half-daily 12 + weekly 168', ...
91     1, [24, 12, 168]);
92
93 best_reg_idx = find_best_by_crps(reg_results);
94 best_reg = reg_results(best_reg_idx);
95
96 %
97 % 3. Evaluate 5 Filter models
98 %
99
100 filter_results(1) = evaluate_filter_model(y, nob, alpha, ...
101     'F1: Delta_24', ...
102     make_diff_filter([24]));
103
```

```

104 filter_results(2) = evaluate_filter_model(y, nob, alpha, ...
105     'F2: Delta_1 Delta_24', ...
106     make_diff_filter([1, 24]));
107
108 filter_results(3) = evaluate_filter_model(y, nob, alpha, ...
109     'F3: Delta_168', ...
110     make_diff_filter([168]));
111
112 filter_results(4) = evaluate_filter_model(y, nob, alpha, ...
113     'F4: Delta_1 Delta_168', ...
114     make_diff_filter([1, 168]));
115
116 filter_results(5) = evaluate_filter_model(y, nob, alpha, ...
117     'F5: Delta_24 Delta_168', ...
118     make_diff_filter([24, 168]));
119
120 best_filter_idx = find_best_by_crps(filter_results);
121 best_filter = filter_results(best_filter_idx);
122
123 % =====
124 % 4. Print comparison tables
125 % =====
126
127 fprintf('\n===== \n');
128 fprintf('Linear Regression Candidate Models \n');
129 fprintf('===== \n');
130 fprintf('%-60s %8s %12s %12s %12s %12s \n', ...
131     'Model', 'Params', 'Train MSE', 'MAE', 'RMSE', 'Med CRPS');
132
133 for i = 1:length(reg_results)
134     fprintf('%-60s %8d %12.3f %12.3f %12.3f %12.3f \n', ...
135         reg_results(i).name, ...
136         reg_results(i).num_params, ...
137         reg_results(i).train_mse, ...
138         reg_results(i).mae, ...
139         reg_results(i).rmse, ...
140         reg_results(i).median_crps);
141 end
142
143 fprintf('\nBest Linear Regression model by median CRPS: \n');
144 fprintf(' %s \n', best_reg.name);
145
146 fprintf('\n===== \n');
147 fprintf('Filter Candidate Models \n');
148 fprintf('===== \n');
149 fprintf('%-35s %8s %12s %12s %12s %12s \n', ...
150     'Model', 'Order', 'Res Std', 'MAE', 'RMSE', 'Med CRPS');
151
152 for i = 1:length(filter_results)
153     fprintf('%-35s %8d %12.3f %12.3f %12.3f %12.3f \n', ...
154         filter_results(i).name, ...
155         filter_results(i).order, ...
156         filter_results(i).residual_std, ...
157         filter_results(i).mae, ...

```

```

158         filter_results(i).rmse, ...
159         filter_results(i).median_crps);
160     end
161
162     fprintf('\nBest Filter model by median CRPS:\n');
163     fprintf(' %s\n', best_filter.name);
164
165     fprintf('\n===== \n');
166     fprintf('Final Selected Models Comparison\n');
167     fprintf('===== \n');
168     fprintf('%-35s %12s %12s %12s %12s\n', ...
169         'Selected model', 'MAE', 'RMSE', 'Coverage', 'Med CRPS');
170
171     fprintf('%-35s %12.3f %12.3f %11.2f%% %12.3f\n', ...
172         best_reg.name, ...
173         best_reg.mae, ...
174         best_reg.rmse, ...
175         100 * best_reg.coverage, ...
176         best_reg.median_crps);
177
178     fprintf('%-35s %12.3f %12.3f %11.2f%% %12.3f\n', ...
179         best_filter.name, ...
180         best_filter.mae, ...
181         best_filter.rmse, ...
182         100 * best_filter.coverage, ...
183         best_filter.median_crps);
184
185     if best_reg.median_crps < best_filter.median_crps
186         fprintf('\nOverall, the selected Linear Regression model has better median
187         CRPS.\n');
188     elseif best_filter.median_crps < best_reg.median_crps
189         fprintf('\nOverall, the selected Filter model has better median CRPS.\n');
190     else
191         fprintf('\nThe selected models have equal median CRPS.\n');
192     end
193
194     write_results_csv('lab6_model_comparison_results.csv', reg_results, filter_results);
195
196     % =====
197     % 5. Plots only for the selected best models
198     % =====
199
200     save_figures = true;
201     npast = min(168, nob - 1);
202     past_idx = (nob - npast:nob)';
203
204     % Figure 1: Dataset and train-test split
205     figure(1);
206     plot(t_all(1:nob), y(1:nob), 'k');
207     hold on;
208     plot(t_all(forecast_idx), y(forecast_idx), 'o-b');
209     yl = ylim;
210     line([nob nob], yl, 'linestyle', '--', 'color', 'k');
211     grid on;

```

```

211 legend('Training data', 'Forecast/test data', 'Train-test split', ...
212         'location', 'northwest');
213 title('Dataset and train-test split');
214 xlabel('Hour');
215 ylabel('GPU resource requests');
216 hold off;
217
218 % Figure 2: Best regression fit on training data
219 figure(2);
220 plot(t_all(1:nob), y(1:nob), 'k');
221 hold on;
222 plot(t_all(1:nob), best_reg.yhat(1:nob), 'r');
223 grid on;
224 legend('Training data', 'Best linear regression fit', ...
225         'location', 'northwest');
226 title(['Best linear regression fit: ', best_reg.name]);
227 xlabel('Hour');
228 ylabel('GPU resource requests');
229 hold off;
230
231 % Figure 3: Best regression forecast
232 figure(3);
233 plot(t_all(past_idx), y(past_idx), 'k');
234 hold on;
235 plot(t_all(forecast_idx), y(forecast_idx), 'o-b');
236 plot(t_all(forecast_idx), best_reg.yhat(forecast_idx), 'r');
237 plot(t_all(forecast_idx), best_reg.upper, 'r-.');
238 plot(t_all(forecast_idx), best_reg.lower, 'r-.');
239 grid on;
240 legend('Past observed data', 'True future values', ...
241         'Best regression forecast', 'Upper 95% PI', 'Lower 95% PI', ...
242         'location', 'northwest');
243 title(['Best linear regression forecast: ', best_reg.name]);
244 xlabel('Hour');
245 ylabel('GPU resource requests');
246 hold off;
247
248 % Figure 4: Best filter residual diagnostics
249 figure(4);
250 res_x = (best_filter.order + 1:nob)';
251 plot(res_x, best_filter.filtered_residuals_centered, 'b');
252 hold on;
253 line([res_x(1) res_x(end)], [0 0], 'linestyle', '--', 'color', 'k');
254 grid on;
255 legend('Centered filtered residuals', 'Zero mean reference', ...
256         'location', 'northwest');
257 title(['Best filter residual diagnostics: ', best_filter.name]);
258 xlabel('Hour');
259 ylabel('Filtered residual');
260 hold off;
261
262 % Figure 5: Best filter forecast
263 figure(5);
264 plot(t_all(past_idx), y(past_idx), 'k');

```

```

265 hold on;
266 plot(t_all(forecast_idx), y(forecast_idx), 'o-b');
267 plot(t_all(forecast_idx), best_filter.yhat(forecast_idx), 'r');
268 plot(t_all(forecast_idx), best_filter.upper, 'r-.');
269 plot(t_all(forecast_idx), best_filter.lower, 'r-.');
270 grid on;
271 legend('Past observed data', 'True future values', ...
272        'Best filter forecast', 'Upper 95% PI', 'Lower 95% PI', ...
273        'location', 'northwest');
274 title(['Best filter forecast: ', best_filter.name]);
275 xlabel('Hour');
276 ylabel('GPU resource requests');
277 hold off;
278
279 % Figure 6: Point forecast comparison
280 figure(6);
281 plot(t_all(forecast_idx), y(forecast_idx), 'o-k');
282 hold on;
283 plot(t_all(forecast_idx), best_reg.yhat(forecast_idx), 'r');
284 plot(t_all(forecast_idx), best_filter.yhat(forecast_idx), 'b');
285 grid on;
286 legend('True future values', 'Selected regression forecast', 'Selected filter
forecast', ...
287        'location', 'northwest');
288 title('Point forecast comparison of selected models');
289 xlabel('Hour');
290 ylabel('GPU resource requests');
291 hold off;
292
293 % Figure 7: Absolute error comparison
294 figure(7);
295 plot(t_all(forecast_idx), abs(best_reg.errors), 'r');
296 hold on;
297 plot(t_all(forecast_idx), abs(best_filter.errors), 'b');
298 grid on;
299 legend('Selected regression absolute error', 'Selected filter absolute error', ...
300        'location', 'northwest');
301 title('Absolute forecast error comparison of selected models');
302 xlabel('Hour');
303 ylabel('Absolute error');
304 hold off;
305
306 % Figure 8: Common forecast comparison with 95% prediction intervals
307 %
308 % This figure directly satisfies the requirement of showing, in one common
309 % graph, the true future values, the forecasts, and the 95% prediction
310 % intervals for the two selected methods.
311 figure(8);
312 plot(t_all(past_idx), y(past_idx), 'k');
313 hold on;
314
315 plot(t_all(forecast_idx), y(forecast_idx), 'o-k');
316
317 plot(t_all(forecast_idx), best_reg.yhat(forecast_idx), 'r');

```

```

318 plot(t_all(forecast_idx), best_reg.upper, 'r-.');
319 plot(t_all(forecast_idx), best_reg.lower, 'r-.');
320
321 plot(t_all(forecast_idx), best_filter.yhat(forecast_idx), 'b');
322 plot(t_all(forecast_idx), best_filter.upper, 'b-.');
323 plot(t_all(forecast_idx), best_filter.lower, 'b-.');
324
325 grid on;
326 legend('Past observed data', 'True future values', ...
327       'Selected regression forecast', 'Regression upper 95% PI', 'Regression lower
95% PI', ...
328       'Selected filter forecast', 'Filter upper 95% PI', 'Filter lower 95% PI', ...
329       'location', 'northwest');
330 title('Selected models forecast comparison with 95% prediction intervals');
331 xlabel('Hour');
332 ylabel('GPU resource requests');
333 hold off;
334
335 if save_figures
336     print(1, 'lab6_fig1_dataset_train_test.png', '-dpng');
337     print(2, 'lab6_fig2_best_regression_fit.png', '-dpng');
338     print(3, 'lab6_fig3_best_regression_forecast.png', '-dpng');
339     print(4, 'lab6_fig4_best_filter_residuals.png', '-dpng');
340     print(5, 'lab6_fig5_best_filter_forecast.png', '-dpng');
341     print(6, 'lab6_fig6_selected_point_forecast_comparison.png', '-dpng');
342     print(7, 'lab6_fig7_selected_absolute_error_comparison.png', '-dpng');
343     print(8, 'lab6_fig8_selected_forecast_intervals_comparison.png', '-dpng');
344
345     % Short aliases, useful for the LaTeX report if you are using lab6_1.png, ...,
lab6_8.png.
346     print(1, 'lab6_1.png', '-dpng');
347     print(2, 'lab6_2.png', '-dpng');
348     print(3, 'lab6_3.png', '-dpng');
349     print(4, 'lab6_4.png', '-dpng');
350     print(5, 'lab6_5.png', '-dpng');
351     print(6, 'lab6_6.png', '-dpng');
352     print(7, 'lab6_7.png', '-dpng');
353     print(8, 'lab6_8.png', '-dpng');
354
355     fprintf('\nSaved figures as PNG files in the current directory.\n');
356 end
357
358 fprintf('\nSaved model comparison metrics to lab6_model_comparison_results.csv.\n');
359 fprintf('Execution completed successfully.\n');
360
361 end
362
363 % =====
364 % Subfunctions
365 % =====
366
367 function result = evaluate_regression_model(y, nob, alpha, model_name, degree,
periods)
368

```

```

369     n = length(y);
370     z = norminv(1 - alpha / 2);
371     forecast_idx = (nob + 1:n)';
372
373     X_all = build_regression_matrix(n, degree, periods);
374     X_train = X_all(1:nob, :);
375
376     p = size(X_train, 2);
377
378     b = X_train \ y(1:nob);
379     yhat = X_all * b;
380
381     residuals = y(1:nob) - X_train * b;
382     train_mse = sum(residuals .^ 2) / nob;
383
384     denom = max(nob - p, 1);
385     sigma2 = sum(residuals .^ 2) / denom;
386     sigma = sqrt(sigma2);
387
388     G = pinv(X_train' * X_train);
389
390     nforecast = n - nob;
391     cint = zeros(nforecast, 1);
392
393     for i = 1:nforecast
394         x0 = X_all(nob + i, :);
395         g = x0 * G * x0';
396         cint(i) = z * sigma * sqrt(1 + g);
397     end
398
399     lower = yhat(forecast_idx) - cint;
400     upper = yhat(forecast_idx) + cint;
401
402     [mae, rmse, coverage, median_crps, crps, errors] = ...
403         compute_forecast_metrics(y(forecast_idx), yhat(forecast_idx), lower, upper, z);
404
405     result.name = model_name;
406     result.type = 'regression';
407     result.degree = degree;
408     result.periods = periods;
409     result.num_params = p;
410     result.coefficients = b;
411     result.yhat = yhat;
412     result.lower = lower;
413     result.upper = upper;
414     result.cint = cint;
415     result.residuals = residuals;
416     result.train_mse = train_mse;
417     result.mae = mae;
418     result.rmse = rmse;
419     result.coverage = coverage;
420     result.median_crps = median_crps;
421     result.crps = crps;
422     result.errors = errors;

```

```

423
424 end
425
426 function X = build_regression_matrix(n, degree, periods)
427
428     t = (1:n)';
429     tau = t / 24; % time measured in days for numerical scaling
430
431     p = degree + 1 + 2 * length(periods);
432     X = zeros(n, p);
433
434     col = 1;
435
436     for k = 0:degree
437         X(:, col) = tau .^ k;
438         col = col + 1;
439     end
440
441     for j = 1:length(periods)
442         T = periods(j);
443
444         X(:, col) = cos(2 * pi * t / T);
445         col = col + 1;
446
447         X(:, col) = sin(2 * pi * t / T);
448         col = col + 1;
449     end
450
451 end
452
453 function result = evaluate_filter_model(y, nob, alpha, model_name, filter_coeffs)
454
455     n = length(y);
456     z = norminv(1 - alpha / 2);
457     forecast_idx = (nob + 1:n)';
458     nforecast = n - nob;
459
460     a = filter_coeffs(:)';
461     q = length(a) - 1;
462
463     if a(1) == 0
464         error('The first filter coefficient must be nonzero.');
```

```

477 yhat = y;
478 cint = zeros(nforecast, 1);
479
480 imp = [1; zeros(nforecast - 1, 1)];
481 inv_h = filter(1, a, imp);
482
483 for k = nob + 1:n
484     horizon = k - nob;
485
486     prediction = residual_mean;
487
488     for j = 1:q
489         prediction = prediction - a(j + 1) * yhat(k - j);
490     end
491
492     prediction = prediction / a(1);
493     yhat(k) = prediction;
494
495     sigma_h = residual_std * sqrt(sum(inv_h(1:horizon) .^ 2));
496     cint(horizon) = z * sigma_h;
497 end
498
499 lower = yhat(forecast_idx) - cint;
500 upper = yhat(forecast_idx) + cint;
501
502 [mae, rmse, coverage, median_crps, crps, errors] = ...
503     compute_forecast_metrics(y(forecast_idx), yhat(forecast_idx), lower, upper, z);
504
505 result.name = model_name;
506 result.type = 'filter';
507 result.coefficients = a;
508 result.order = q;
509 result.yhat = yhat;
510 result.lower = lower;
511 result.upper = upper;
512 result.cint = cint;
513 result.filtered_residuals_raw = raw_filtered;
514 result.filtered_residuals_centered = centered_residuals;
515 result.residual_mean = residual_mean;
516 result.residual_std = residual_std;
517 result.mae = mae;
518 result.rmse = rmse;
519 result.coverage = coverage;
520 result.median_crps = median_crps;
521 result.crps = crps;
522 result.errors = errors;
523
524 end
525
526 function res = apply_filter_to_training(y_train, a)
527
528     q = length(a) - 1;
529     n = length(y_train);
530     m = n - q;

```

```

531
532     res = zeros(m, 1);
533
534     for i = 1:m
535         t = q + i;
536         value = 0;
537
538         for j = 0:q
539             value = value + a(j + 1) * y_train(t - j);
540         end
541
542         res(i) = value;
543     end
544
545 end
546
547 function a = make_diff_filter(lags)
548
549     a = 1;
550
551     for i = 1:length(lags)
552         L = lags(i);
553
554         if L < 1
555             error('All differencing lags must be positive integers.');
```

556 end

557

558 b = [1, zeros(1, L - 1), -1];

559 a = conv(a, b);

560 end

561

562 end

563

564 function [mae, rmse, coverage, median_crps, crps, errors] = ...

565 compute_forecast_metrics(y_true, mu, lower, upper, z)

566

567 y_true = y_true(:);

568 mu = mu(:);

569 lower = lower(:);

570 upper = upper(:);

571

572 errors = y_true - mu;

573

574 mae = mean(abs(errors));

575 rmse = sqrt(mean(errors .^ 2));

576 coverage = mean((y_true >= lower) & (y_true <= upper));

577

578 sigma = (upper - mu) / z;

579 sigma(sigma <= 0) = eps;

580

581 crps = zeros(length(y_true), 1);

582

583 for i = 1:length(y_true)

584 a = (y_true(i) - mu(i)) / sigma(i);

```

585     crps(i) = sigma(i) * ...
586         (a * (2 * normcdf(a) - 1) + 2 * normpdf(a) - 1 / sqrt(pi));
587 end
588
589     median_crps = median(crps);
590
591 end
592
593 function idx = find_best_by_crps(results)
594
595     values = zeros(length(results), 1);
596
597     for i = 1:length(results)
598         values(i) = results(i).median_crps;
599     end
600
601     [~, idx] = min(values);
602
603 end
604
605 function write_results_csv(filename, reg_results, filter_results)
606
607     fid = fopen(filename, 'w');
608
609     if fid < 0
610         warning('Could not write results CSV file.');
```

return;

```

612     end
613
614     fprintf(fid,
'category,model,train_mse_or_residual_std,mae,rmse,coverage,median_crps\n');
615
616     for i = 1:length(reg_results)
617         fprintf(fid, 'regression,"%s",%.10f,%.10f,%.10f,%.10f,%.10f\n', ...
618             reg_results(i).name, ...
619             reg_results(i).train_mse, ...
620             reg_results(i).mae, ...
621             reg_results(i).rmse, ...
622             reg_results(i).coverage, ...
623             reg_results(i).median_crps);
624     end
625
626     for i = 1:length(filter_results)
627         fprintf(fid, 'filter,"%s",%.10f,%.10f,%.10f,%.10f,%.10f\n', ...
628             filter_results(i).name, ...
629             filter_results(i).residual_std, ...
630             filter_results(i).mae, ...
631             filter_results(i).rmse, ...
632             filter_results(i).coverage, ...
633             filter_results(i).median_crps);
634     end
635
636     fclose(fid);
637

```


8.2 Έξοδος Προγράμματος

=====

Lab 6 - Basic Forecasting with Model Selection

=====

Loaded dataset: dataset.mat
 Number of observations: 1247
 Training observations: 1200
 Forecast observations: 47
 Forecast horizon: 1201 to 1247
 Confidence level: 95%

=====

Linear Regression Candidate Models

=====

Model	Params	Train
MSE		
MAE		
RMSE		
Med CRPS		
LR1: constant + daily 24	3	
521883.168		538.035
791.283		260.300
LR2: linear trend + daily 24	4	
513540.892		458.657
710.656		232.094
LR3: linear trend + daily 24 + weekly 168	6	
498776.282		419.878
675.712		209.130
LR4: quadratic trend + daily 24 + weekly 168	7	
497531.338		437.483
702.799		215.583
LR5: linear trend + daily 24 + half-daily 12 + weekly 168	8	
490046.575		402.893
644.796		235.488

Best Linear Regression model by median CRPS:
 LR3: linear trend + daily 24 + weekly 168

=====

Filter Candidate Models

=====

Model	Order	Res Std	MAE
RMSE			
Med CRPS			
F1: Delta_24	24	904.672	475.487
734.967			310.531
F2: Delta_1 Delta_24	25	1110.336	753.587
1043.372			1338.159
F3: Delta_168	168	955.139	616.918
864.900			296.036
F4: Delta_1 Delta_168	169	1176.400	970.518
1219.322			1402.320
F5: Delta_24 Delta_168	192	1267.724	832.639
1308.248			456.351

Best Filter model by median CRPS:
 F3: Delta_168

=====

Final Selected Models Comparison

=====

Selected model	MAE	RMSE	Coverage
----------------	-----	------	----------

Med CRPS

LR3: linear trend + daily 24 + weekly 168	419.878	675.712	97.87%
209.130			
F3: Delta_168	616.918	864.900	97.87%
296.036			

Overall, the selected Linear Regression model has better median CRPS.

Saved figures as PNG files in the current directory.

Saved model comparison metrics to lab6_model_comparison_results.csv.
Execution completed successfully.