

ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ

Τομέας Επικοινωνιών, Ηλεκτρονικής και Συστημάτων Πληροφορικής
Εργαστήριο Διαχείρισης και Βέλτιστου Σχεδιασμού Δικτύων Τηλεματικής - NETMODE

Συστήματα Αναμονής
Ανασκόπηση Εργαστηριακού Μέρους του Μαθήματος



Στοιχεία Φοιτητή

- Όνομα: Πέππας Μιχαήλ-Αθανάσιος
- Αριθμός Μητρώου: 03121026
- 4^η Εργαστηριακή Ομάδα (Δευτέρα, 12:45-14:30)

Περιεχόμενα

1	1η Εργαστηριακή Άσκηση: Poisson, Εκθετική Κατανομή και Διαδικασία Poisson	5
1.1	Θεωρητικός πυρήνας της άσκησης	5
1.2	Διαδικασία Poisson και σύνδεση με συστήματα αναμονής	6
1.3	Ποιοτικά συμπεράσματα	8
1.4	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	8
2	2η Εργαστηριακή Άσκηση: Ουρά M/M/1 και Διαδικασίες Γεννήσεων-Θανάτων	11
2.1	Θεωρητικός πυρήνας της άσκησης	11
2.2	Εργοδικές πιθανότητες της M/M/1	12
2.3	Μέσες μετρικές και νόμος Little	13
2.4	Πεπερασμένη χωρητικότητα και birth-death μοντέλα	14
2.5	Ποιοτικά συμπεράσματα	15
2.6	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	15
3	3η Εργαστηριακή Άσκηση: Προσομοίωση Συστήματος M/M/1/10	18
3.1	Θεωρητικός πυρήνας της άσκησης	18
3.2	Non-terminating simulation και transient period	19
3.3	Ποιοτική συμπεριφορά ως προς το φορτίο	19
3.4	Event-driven λογική προσομοίωσης	20
3.5	Time averages και σωστή εκτίμηση μετρικών	21
3.6	State-dependent ρυθμός εξυπηρέτησης	22
3.7	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	23
4	4η Εργαστηριακή Άσκηση: Τηλεφωνικά Κέντρα, M/M/c και Erlang C	25
4.1	Θεωρητικός πυρήνας της άσκησης	25

4.2	PBX ως σύστημα M/M/c	25
4.3	Offered load, actual load και utilization	26
4.4	Erlang C: πιθανότητα αναμονής, Service Level και ASA	27
4.5	Ποιοτική ερμηνεία Erlang C	29
4.6	Πρακτική διάσταση: staffing, occupancy και shrinkage	29
4.7	Erlang A και εγκατάλειψη ουράς	30
4.8	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	31
5	5η Εργαστηριακή Άσκηση: Προσομοίωση Διακριτών Γεγονότων και Ανοικτά Δίκτυα Jackson	34
5.1	Θεωρητικός πυρήνας της άσκησης	34
5.2	Προσομοίωση διακριτών γεγονότων του Web Server	34
5.3	Δομή της DES προσομοίωσης	35
5.4	Στασιμότητα του Web Server	36
5.5	Χρονικά σταθμισμένοι μέσοι όροι	37
5.6	Μεταβατική περίοδος και μέθοδος MQS	38
5.7	Διαστήματα εμπιστοσύνης και ανεξάρτητες επαναλήψεις	38
5.8	Επαλήθευση του νόμου Little	39
5.9	Ανοικτό δίκτυο ουρών Jackson	40
5.10	Εξισώσεις ροής και effective arrival rates	41
5.11	Μέσος αριθμός πελατών και end-to-end καθυστέρηση	41
5.12	Στενωπός και μέγιστος ρυθμός εισόδου	42
5.13	Ποιοτικά συμπεράσματα	43
5.14	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	44
6	6η Εργαστηριακή Άσκηση: Πρόβλεψη Χρονοσειράς Φόρτου	48
6.1	Στόχος της άσκησης	48
6.2	Δεδομένα και βασικό πρόβλημα πρόβλεψης	48
6.3	Prediction intervals και confidence intervals	49

6.4	Μέθοδος 1: Γραμμική παλινδρόμηση	50
6.5	Residuals και overfitting στη γραμμική παλινδρόμηση	51
6.6	Μέθοδος 2: Φίλτρα και διαφοροποίηση	52
6.7	Stationarity και over-differencing	53
6.8	Πρόβλεψη με φίλτρα και αντίστροφο φίλτρο	53
6.9	Μετρικές αξιολόγησης	54
6.10	Ποιοτική ερμηνεία των αποτελεσμάτων της αναφοράς	55
6.11	Κρίσιμα σημεία για την προφορική εξέταση	56
6.12	Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης	57

1 1η Εργαστηριακή Άσκηση: Poisson, Εκθετική Κατανομή και Διαδικασία Poisson

1.1 Θεωρητικός πυρήνας της άσκησης

Η 1η εργαστηριακή άσκηση εισάγει τα βασικά πιθανοτικά εργαλεία που χρησιμοποιούνται σε όλα τα Markovian μοντέλα ουρών: την κατανομή Poisson, την εκθετική κατανομή και τη διαδικασία Poisson. Η βασική ιδέα είναι ότι η Poisson περιγράφει **πλήθος γεγονότων**, ενώ η εκθετική περιγράφει **χρόνο μέχρι το επόμενο γεγονός**.

Αν $X \sim \text{Poisson}(\lambda)$, τότε:

$$P(X = k) = e^{-\lambda} \frac{\lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

και:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

Η Poisson είναι διακριτή κατανομή. Άρα έχει συνάρτηση μάζας πιθανότητας, δηλαδή PMF, και όχι συνάρτηση πυκνότητας πιθανότητας. Η παράμετρος λ εκφράζει τον μέσο αριθμό γεγονότων στο υπό εξέταση διάστημα. Όταν αυξάνεται το λ , η κατανομή μετατοπίζεται προς μεγαλύτερες τιμές, απλώνεται περισσότερο και προσεγγίζει πιο συμμετρική μορφή.

Η σύνδεση της Poisson με τη διωνυμική κατανομή είναι θεμελιώδης. Αν:

$$X_n \sim \text{Bin}(n, p)$$

και ισχύει:

$$n \rightarrow \infty, \quad p \rightarrow 0, \quad np = \lambda,$$

τότε:

$$\text{Bin}(n, p) \rightarrow \text{Poisson}(\lambda).$$

Άρα η Poisson εμφανίζεται όταν έχουμε πολλές ανεξάρτητες δοκιμές, μικρή πιθανότητα επιτυχίας σε κάθε δοκιμή και σταθερό μέσο πλήθος επιτυχιών. Αυτό είναι σημαντικό για τη μοντελοποίηση σπάνιων γεγονότων, όπως αφίξεις κλήσεων, πακέτων ή πελατών.

Η εκθετική κατανομή χρησιμοποιείται για χρόνο αναμονής μέχρι το επόμενο γεγονός. Αν $X \sim \text{Exp}(\lambda)$, τότε:

$$f_X(x) = \lambda e^{-\lambda x}, \quad x \geq 0,$$

$$F_X(x) = 1 - e^{-\lambda x},$$

και:

$$E[X] = \frac{1}{\lambda}.$$

Το σημαντικότερο χαρακτηριστικό της εκθετικής κατανομής είναι η ιδιότητα απώλειας μνήμης:

$$P(X > t + s \mid X > s) = P(X > t).$$

Αυτό σημαίνει ότι, αν έχει ήδη περάσει χρόνος s χωρίς να συμβεί το γεγονός, η κατανομή του υπολειπόμενου χρόνου είναι ίδια με την αρχική. Το σύστημα δεν “θυμάται” το παρελθόν. Αυτή η ιδιότητα είναι η βάση της Markovian μοντελοποίησης στα συστήματα αναμονής.

1.2 Διαδικασία Poisson και σύνδεση με συστήματα αναμονής

Η διαδικασία Poisson $N(t)$ μετρά πόσα γεγονότα έχουν συμβεί μέχρι τον χρόνο t . Αν η διαδικασία έχει ρυθμό λ , τότε:

$$N(t) \sim \text{Poisson}(\lambda t).$$

Οι χρόνοι μεταξύ διαδοχικών γεγονότων είναι ανεξάρτητες εκθετικές τυχαίες μεταβλητές:

$$T_i \sim \text{Exp}(\lambda).$$

Άρα η διαδικασία Poisson συνδέει τις δύο κατανομές:

- η Poisson περιγράφει πόσα γεγονότα έγιναν σε χρονικό διάστημα,
- η εκθετική περιγράφει πόσος χρόνος πέρασε μέχρι το επόμενο γεγονός.

Η διαδικασία Poisson έχει δύο βασικές ιδιότητες:

1. **Στάσιμες αυξήσεις:** το πλήθος γεγονότων σε διάστημα μήκους t εξαρτάται μόνο από το μήκος του διαστήματος και όχι από τη θέση του στον χρόνο.
2. **Ανεξάρτητες αυξήσεις:** τα πλήθη γεγονότων σε ξένα χρονικά διαστήματα είναι ανεξάρτητα.

Στη θεωρία ουρών, οι αφίξεις πελατών μοντελοποιούνται συχνά ως διαδικασία Poisson. Για αυτό το πρώτο M στο $M/M/1$ δηλώνει Markovian αφίξεις, δηλαδή αφίξεις Poisson και εκθετικούς χρόνους μεταξύ αφίξεων.

Δύο ακόμη σημαντικές ιδιότητες της Poisson είναι η διάσπαση και η υπέρθεση.

Διάσπαση Poisson. Αν μία ροή Poisson με ρυθμό λ χωρίζεται ανεξάρτητα σε δύο κατηγορίες με πιθανότητες p και $1 - p$, τότε οι δύο επιμέρους ροές είναι Poisson με ρυθμούς:

$$p\lambda \quad \text{και} \quad (1 - p)\lambda.$$

Υπέρθεση Poisson. Αν δύο ανεξάρτητες ροές Poisson έχουν ρυθμούς λ_1 και λ_2 , τότε η συνολική ροή είναι Poisson με ρυθμό:

$$\lambda_1 + \lambda_2.$$

Προσοχή: αν γνωρίζουμε το συνολικό πλήθος γεγονότων, τότε η κατανομή του πλήθους μιας επιμέρους κατηγορίας δεν είναι Poisson αλλά διωνυμική. Δηλαδή, υπό συνθήκη στο συνολικό πλήθος, χρησιμοποιούμε Binomial.

1.3 Ποιοτικά συμπεράσματα

Η 1η άσκηση δείχνει ότι τα βασικά μοντέλα ουρών δεν ξεκινούν από αυθαίρετους τύπους, αλλά από συγκεκριμένες στοχαστικές παραδοχές:

- τυχαίες αφίξεις με σταθερό μέσο ρυθμό οδηγούν σε Poisson πλήθη,
- οι χρόνοι μεταξύ αφίξεων σε διαδικασία Poisson είναι εκθετικοί,
- η εκθετική κατανομή δίνει την ιδιότητα Markov,
- το ελάχιστο ανεξάρτητων εκθετικών χρόνων είναι ξανά εκθετικό,
- οι Poisson ροές μπορούν να διασπώνται και να υπερτίθενται.

Αυτές οι έννοιες είναι προαπαιτούμενες για τα $M/M/1$, $M/M/1/K$, $M/M/c$ και Erlang μοντέλα που εμφανίζονται στις επόμενες ασκήσεις.

1.4 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. Τι περιγράφει η κατανομή Poisson;

Περιγράφει το πλήθος γεγονότων που συμβαίνουν σε ένα χρονικό ή χωρικό διάστημα, όταν τα γεγονότα εμφανίζονται ανεξάρτητα με σταθερό μέσο ρυθμό λ .

2. Γιατί η Poisson έχει PMF και όχι PDF;

Επειδή είναι διακριτή κατανομή και παίρνει τιμές $0, 1, 2, \dots$. Άρα υπολογίζουμε πιθανότητες σημείων $P(X = k)$, όχι πυκνότητα σε συνεχές πεδίο.

3. Ποια είναι η μέση τιμή και η διακύμανση της Poisson;

Για $X \sim \text{Poisson}(\lambda)$ ισχύει:

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda.$$

Αυτό είναι χαρακτηριστικό της Poisson: ο μέσος και η διασπορά ταυτίζονται.

4. Πότε η διωνυμική προσεγγίζεται από Poisson;

Όταν n είναι μεγάλο, p μικρό και $np = \lambda$ σταθερό. Τότε:

$$\text{Bin}(n, p) \approx \text{Poisson}(\lambda).$$

5. **Τι περιγράφει η εκθετική κατανομή σε μία διαδικασία Poisson;**

Περιγράφει τον χρόνο μέχρι το επόμενο γεγονός ή τον χρόνο μεταξύ δύο διαδοχικών γεγονότων.

6. **Ποια είναι η ιδιότητα απώλειας μνήμης;**

Είναι η σχέση:

$$P(X > t + s \mid X > s) = P(X > t).$$

Σημαίνει ότι ο υπολειπόμενος χρόνος αναμονής δεν εξαρτάται από το πόσο έχουμε ήδη περιμένει.

7. **Γιατί η απώλεια μνήμης είναι σημαντική για τα Markov μοντέλα;**

Επειδή επιτρέπει το μέλλον να εξαρτάται μόνο από την τρέχουσα κατάσταση και όχι από το ιστορικό του συστήματος. Για παράδειγμα, σε ένα $M/M/1$ αρκεί να γνωρίζουμε πόσοι πελάτες υπάρχουν στο σύστημα.

8. **Τι κατανομή έχει το ελάχιστο ανεξάρτητων εκθετικών χρόνων;**

Αν $X_i \sim \text{Exp}(\lambda_i)$ ανεξάρτητες, τότε:

$$\min_i X_i \sim \text{Exp} \left(\sum_i \lambda_i \right).$$

Αυτό χρησιμοποιείται όταν ανταγωνίζονται διαφορετικά πιθανά επόμενα γεγονότα.

9. **Τι σημαίνει διάσπαση Poisson;**

Αν κάθε γεγονός μιας Poisson ροής ταξινομείται ανεξάρτητα σε κατηγορίες, τότε κάθε επιμέρους κατηγορία σχηματίζει επίσης Poisson ροή.

10. **Τι σημαίνει υπέρθεση Poisson;**

Το άθροισμα ανεξάρτητων Poisson ροών είναι ξανά Poisson, με ρυθμό ίσο με το άθροισμα των επιμέρους ρυθμών.

11. **Πότε χρησιμοποιούμε διωνυμική αντί για Poisson στη διάσπαση;**

Όταν γνωρίζουμε το συνολικό πλήθος γεγονότων. Τότε ο αριθμός γεγονότων μιας κατηγορίας, δεδομένου του συνολικού πλήθους, ακολουθεί διωνυμική κατανομή.

12. Γιατί η διαδικασία $N(t)$ σχεδιάζεται με κλιμακωτή μορφή;

Επειδή το πλήθος γεγονότων μένει σταθερό μεταξύ δύο αφίξεων και αυξάνεται κατά μία μονάδα τη στιγμή κάθε νέου γεγονότος.

2 2η Εργαστηριακή Άσκηση: Ουρά $M/M/1$ και Διαδικασίες Γεννήσεων-Θανάτων

2.1 Θεωρητικός πυρήνας της άσκησης

Η 2η εργαστηριακή άσκηση εισάγει το βασικό Markovian σύστημα ουράς $M/M/1$. Ο συμβολισμός σημαίνει:

- το πρώτο M δηλώνει αφίξεις Poisson με ρυθμό λ ,
- το δεύτερο M δηλώνει εκθετικούς χρόνους εξυπηρέτησης με ρυθμό μ ,
- το 1 δηλώνει έναν εξυπηρετητή.

Η κατάσταση του συστήματος είναι:

$$n(t) = 0, 1, 2, \dots$$

δηλαδή ο αριθμός πελατών στο σύστημα, είτε περιμένουν είτε εξυπηρετούνται.

Η ουρά $M/M/1$ είναι διαδικασία γεννήσεων-θανάτων. Οι αφίξεις είναι γεννήσεις:

$$n \rightarrow n + 1$$

με ρυθμό λ , ενώ οι αναχωρήσεις είναι θάνατοι:

$$n \rightarrow n - 1$$

με ρυθμό μ , όταν $n > 0$.

Ο βαθμός χρησιμοποίησης είναι:

$$\rho = \frac{\lambda}{\mu}.$$

Η ουρά είναι εργοδική μόνο όταν:

$$\rho < 1 \quad \Leftrightarrow \quad \lambda < \mu.$$

Αν $\lambda \geq \mu$, τότε ο εξυπηρετητής δεν μπορεί μακροπρόθεσμα να εξυπηρετήσει τις αφίξεις. Η ουρά αυξάνεται χωρίς φράγμα και δεν υπάρχει στάσιμη κατανομή.

2.2 Εργοδικές πιθανότητες της M/M/1

Από τις λεπτομερείς εξισώσεις ισορροπίας:

$$\lambda P_{k-1} = \mu P_k,$$

προκύπτει:

$$P_k = \rho^k P_0.$$

Με την κανονικοποίηση:

$$\sum_{k=0}^{\infty} P_k = 1,$$

και επειδή η γεωμετρική σειρά συγκλίνει μόνο για $\rho < 1$, παίρνουμε:

$$P_0 = 1 - \rho.$$

Άρα:

$$P_k = (1 - \rho)\rho^k, \quad k = 0, 1, 2, \dots$$

Η κατανομή του πλήθους πελατών είναι γεωμετρική. Αυτό σημαίνει ότι η πιθανότητα μεγάλων ουρών μειώνεται γεωμετρικά όταν $\rho < 1$. Όσο όμως το ρ πλησιάζει το 1, η μείωση γίνεται αργή και οι μεγάλες ουρές γίνονται πολύ πιθανότερες.

Η πιθανότητα το σύστημα να μην είναι άδειο είναι:

$$P(n(t) > 0) = 1 - P_0 = \rho.$$

Άρα το ρ είναι ταυτόχρονα:

- βαθμός χρησιμοποίησης του εξυπηρετητή,

- πιθανότητα ο εξυπηρετητής να είναι απασχολημένος,
- βασικός δείκτης φόρτου του συστήματος.

2.3 Μέσες μετρικές και νόμος Little

Ο μέσος αριθμός πελατών στο σύστημα είναι:

$$L = E[n] = \frac{\rho}{1 - \rho} = \frac{\lambda}{\mu - \lambda}.$$

Ο μέσος χρόνος παραμονής στο σύστημα είναι:

$$E[T] = \frac{1}{\mu - \lambda}.$$

Ο χρόνος αυτός περιλαμβάνει και την αναμονή στην ουρά και την εξυπηρέτηση. Αν W είναι ο χρόνος αναμονής πριν αρχίσει η εξυπηρέτηση και s ο χρόνος εξυπηρέτησης, τότε:

$$T = W + s.$$

Επειδή:

$$E[s] = \frac{1}{\mu},$$

παίρνουμε:

$$E[W] = E[T] - \frac{1}{\mu} = \frac{\lambda}{\mu(\mu - \lambda)}.$$

Τα παραπάνω μπορούν να εξηγηθούν και μέσω του νόμου Little:

$$L = \lambda E[T].$$

Ο νόμος Little είναι γενικός και συνδέει τον μέσο αριθμό πελατών στο σύστημα με τον ρυθμό εισόδου και τον μέσο χρόνο παραμονής.

Το πιο σημαντικό ποιοτικό συμπέρασμα είναι ότι, όταν:

$$\rho \rightarrow 1,$$

τότε:

$$L \rightarrow \infty, \quad E[T] \rightarrow \infty, \quad E[W] \rightarrow \infty.$$

Άρα ένα σύστημα μπορεί να είναι θεωρητικά εργοδικό, αλλά πρακτικά κακό, αν λειτουργεί πολύ κοντά στον κορεσμό.

2.4 Πεπερασμένη χωρητικότητα και birth-death μοντέλα

Στην άσκηση εμφανίζεται και σύστημα $M/M/1/K$, ειδικά $M/M/1/3$. Εκεί το state space είναι πεπερασμένο:

$$\{0, 1, 2, 3\}.$$

Η βασική διαφορά από την $M/M/1$ είναι ότι όταν το σύστημα φτάσει στη μέγιστη χωρητικότητα, οι νέοι πελάτες δεν μπορούν να εισέλθουν. Άρα υπάρχει πιθανότητα blocking.

Σε γενική birth-death process με state-dependent ρυθμούς λ_i και μ_i , οι εργοδικές πιθανότητες υπολογίζονται αλυσιδωτά:

$$P_i = P_0 \prod_{j=0}^{i-1} \frac{\lambda_j}{\mu_{j+1}}.$$

Η σταθερά P_0 βρίσκεται από την κανονικοποίηση:

$$\sum_i P_i = 1.$$

Η αναφορά συνδέει επίσης το σύστημα με CTMC και generator matrix Q . Ο πίνακας Q δεν είναι πίνακας πιθανοτήτων. Είναι πίνακας ρυθμών. Για $i \neq j$, το q_{ij} είναι ο ρυθμός μετάβασης από την κατάσταση i στην κατάσταση j , ενώ:

$$q_{ii} = -\sum_{j \neq i} q_{ij}.$$

Άρα κάθε γραμμή του Q αθροίζει σε μηδέν.

2.5 Ποιοτικά συμπεράσματα

Η άσκηση δείχνει τέσσερα βασικά πράγματα:

1. Η $M/M/1$ είναι το απλούστερο Markovian σύστημα ουράς με αναλυτική λύση.
2. Η εργοδικότητα απαιτεί αυστηρά $\lambda < \mu$.
3. Η αύξηση του ρ αυξάνει πολύ έντονα καθυστέρηση και μήκος ουράς.
4. Η πεπερασμένη χωρητικότητα αποτρέπει την άπειρη αύξηση, αλλά εισάγει απορρίψεις.

Έτσι, η 2η άσκηση είναι η γέφυρα από τις απλές κατανομές της 1ης άσκησης στη θεωρία ουρών με ισορροπία, throughput, καθυστέρηση και blocking.

2.6 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. **Τι σημαίνει ο συμβολισμός $M/M/1$;**

Σημαίνει Poisson αφίξεις, εκθετικούς χρόνους εξυπηρέτησης και έναν εξυπηρετητή.

2. **Γιατί η $M/M/1$ είναι birth-death process;**

Επειδή η κατάσταση είναι ο αριθμός πελατών και κάθε γεγονός αλλάζει την κατάσταση μόνο κατά $+1$ ή -1 .

3. **Ποια είναι η συνθήκη εργοδικότητας;**

$$\rho = \frac{\lambda}{\mu} < 1.$$

Δηλαδή ο ρυθμός εξυπηρέτησης πρέπει να είναι μεγαλύτερος από τον ρυθμό αφίξεων.

4. **Τι συμβαίνει αν $\lambda = \mu$;**

Η ουρά $M/M/1$ δεν είναι εργοδική. Είναι οριακή περίπτωση και δεν υπάρχει κανονικοποιήσιμη στάσιμη κατανομή.

5. **Πώς προκύπτουν οι εργοδικές πιθανότητες;**

Από τις τοπικές εξισώσεις ισορροπίας:

$$\lambda P_{k-1} = \mu P_k,$$

που οδηγούν σε:

$$P_k = (1 - \rho)\rho^k.$$

6. **Γιατί χρειάζεται η συνθήκη $\rho < 1$ στον υπολογισμό του P_0 ;**

Επειδή η κανονικοποίηση περιλαμβάνει άπειρη γεωμετρική σειρά:

$$\sum_{k=0}^{\infty} \rho^k,$$

η οποία συγκλίνει μόνο αν $\rho < 1$.

7. **Ποια είναι η φυσική ερμηνεία του ρ ;**

Είναι το ποσοστό χρόνου που ο εξυπηρετητής είναι απασχολημένος. Επίσης είναι η πιθανότητα το σύστημα να μην είναι άδειο.

8. **Ποια είναι η σχέση του νόμου Little με την άσκηση;**

Ο νόμος Little δίνει:

$$L = \lambda E[T].$$

Χρησιμοποιείται για να συνδέσουμε το μέσο πλήθος πελατών με τον μέσο χρόνο παραμονής.

9. **Ποια είναι η διαφορά μεταξύ T και W ;**

Το T είναι ο συνολικός χρόνος στο σύστημα, ενώ το W είναι μόνο ο χρόνος αναμονής στην ουρά. Ισχύει:

$$T = W + s.$$

10. **Γιατί το throughput της εργοδικής $M/M/1$ είναι ίσο με λ ;**

Επειδή η χωρητικότητα είναι άπειρη και δεν υπάρχουν απώλειες. Άρα όλοι οι πελάτες που φτάνουν τελικά εξυπηρετούνται.

11. **Τι αλλάζει σε $M/M/1/K$;**

Το state space είναι πεπερασμένο και όταν το σύστημα γεμίσει, νέες αφίξεις απορρίπτονται. Άρα υπάρχει blocking probability.

12. Τι είναι ο generator matrix Q ;

Είναι ο πίνακας ρυθμών μετάβασης μιας CTMC. Τα εκτός διαγωνίου στοιχεία είναι ρυθμοί μετάβασης και οι διαγώνιοι είναι αρνητικοί συνολικοί ρυθμοί εξόδου.

13. Γιατί κάθε γραμμή του Q αθροίζει σε μηδέν;

Επειδή το διαγώνιο στοιχείο είναι το αρνητικό άθροισμα των υπόλοιπων ρυθμών εξόδου από την κατάσταση.

14. Τι σημαίνει state-dependent birth-death process;

Σημαίνει ότι οι ρυθμοί λ_i ή/και μ_i εξαρτώνται από την τρέχουσα κατάσταση του συστήματος.

3 3η Εργαστηριακή Άσκηση: Προσομοίωση Συστήματος M/M/1/10

3.1 Θεωρητικός πυρήνας της άσκησης

Η 3η εργαστηριακή άσκηση μελετά μέσω προσομοίωσης ένα σύστημα $M/M/1/10$. Το σύστημα έχει:

- αφίξεις Poisson,
- εκθετικούς χρόνους εξυπηρέτησης,
- έναν εξυπηρετητή,
- συνολική χωρητικότητα $K = 10$ πελάτες.

Το state space είναι:

$$\{0, 1, 2, \dots, 10\}.$$

Η βασική διαφορά από το $M/M/1$ είναι ότι το σύστημα δεν μπορεί να αυξηθεί απεριόριστα. Όταν βρίσκεται στην κατάσταση 10, κάθε νέα άφιξη απορρίπτεται. Άρα έχουμε ουρά με απώλειες.

Για $M/M/1/K$, αν:

$$\rho = \frac{\lambda}{\mu},$$

τότε οι εργοδικές πιθανότητες είναι:

$$P_n = \frac{(1 - \rho)\rho^n}{1 - \rho^{K+1}}, \quad \rho \neq 1,$$

ενώ για $\rho = 1$:

$$P_n = \frac{1}{K + 1}.$$

Η πιθανότητα απόρριψης είναι:

$$P_{\text{rej}} = P_K.$$

Επειδή μόνο οι αποδεκτοί πελάτες εισέρχονται στο σύστημα, ο ενεργός ρυθμός εισόδου είναι:

$$\lambda_{\text{eff}} = \lambda(1 - P_{\text{rej}}).$$

Ο μέσος χρόνος παραμονής υπολογίζεται με τον νόμο Little ως:

$$W = \frac{L}{\lambda_{\text{eff}}}.$$

3.2 Non-terminating simulation και transient period

Η προσομοίωση της άσκησης είναι non-terminating simulation. Δεν υπάρχει φυσικό τέλος της λειτουργίας του συστήματος. Μας ενδιαφέρει η μακροχρόνια συμπεριφορά του, δηλαδή οι στάσιμες πιθανότητες και οι μέσες μετρικές.

Το σύστημα ξεκινά από την αρχική κατάσταση:

$$n(0) = 0.$$

Αυτή όμως είναι τεχνητή αρχική συνθήκη. Στην πραγματική μόνιμη λειτουργία, το σύστημα δεν ξεκινά πάντα άδειο. Άρα οι πρώτες παρατηρήσεις μπορεί να είναι μεροληπτικές.

Η αρχική αυτή φάση ονομάζεται transient period.

Για αυτό η άσκηση συγκρίνει δύο εκτιμήσεις:

- μία με όλες τις μεταβάσεις,
- μία αφού αγνοηθούν οι πρώτες B μεταβάσεις.

Η αφαίρεση του transient δεν αλλάζει το μοντέλο. Αλλάζει μόνο το ποια δεδομένα χρησιμοποιούνται για την εκτίμηση των μετρικών. Στόχος είναι να πλησιάσουμε περισσότερο τη στάσιμη συμπεριφορά.

3.3 Ποιοτική συμπεριφορά ως προς το φορτίο

Η άσκηση εξετάζει τρία καθεστώτα λειτουργίας:

Υποφορτισμένο σύστημα: $\lambda < \mu$. Το σύστημα δέχεται λιγότερη κίνηση από όση μπορεί να εξυπηρετήσει. Παραμένει συχνά άδειο ή σχεδόν άδειο. Το blocking είναι σχεδόν μηδενικό και ο μέσος αριθμός πελατών μικρός.

Οριακό σύστημα: $\lambda = \mu$. Στο άπειρης χωρητικότητας $M/M/1$, η περίπτωση αυτή θα ήταν μη εργοδική. Στο $M/M/1/10$, όμως, το state space είναι πεπερασμένο και υπάρχει στάσιμη κατανομή. Για $\rho = 1$, όλες οι καταστάσεις είναι ισοπίθανες:

$$P_n = \frac{1}{11}, \quad n = 0, \dots, 10.$$

Άρα το σύστημα επισκέπτεται με παρόμοια συχνότητα όλες τις καταστάσεις.

Υπερφορτισμένο σύστημα: $\lambda > \mu$. Στο άπειρο $M/M/1$ αυτό θα οδηγούσε σε αστάθεια. Στο $M/M/1/10$, όμως, το πλήθος πελατών δεν μπορεί να ξεπεράσει το 10. Άρα η υπερφόρτωση εμφανίζεται ως υψηλή πιθανότητα πλήρους συστήματος και υψηλό blocking.

Το κρίσιμο θεωρητικό σημείο είναι ότι η πεπερασμένη χωρητικότητα δεν εξαφανίζει το πρόβλημα του μεγάλου φορτίου. Απλώς το μετατρέπει από αστάθεια σε απώλειες.

3.4 Event-driven λογική προσομοίωσης

Η προσομοίωση είναι event-driven. Αυτό σημαίνει ότι ο χρόνος προχωρά από γεγονός σε γεγονός και όχι με σταθερό βήμα.

Αν το σύστημα είναι άδειο, δηλαδή $n = 0$, δεν μπορεί να συμβεί αναχώρηση. Άρα το επόμενο γεγονός είναι υποχρεωτικά άφιξη.

Αν $n > 0$, υπάρχουν δύο δυνατά γεγονότα:

arrival και departure.

Ο συνολικός ρυθμός είναι:

$$\lambda + \mu.$$

Ο χρόνος μέχρι το επόμενο γεγονός είναι:

$$\Delta t \sim \text{Exp}(\lambda + \mu),$$

και:

$$P(\text{arrival}) = \frac{\lambda}{\lambda + \mu}, \quad P(\text{departure}) = \frac{\mu}{\lambda + \mu}.$$

Σε άφιξη:

$$n \rightarrow n + 1, \quad \text{αν } n < 10.$$

Αν $n = 10$, η άφιξη απορρίπτεται και:

$$n \rightarrow n.$$

Σε αναχώρηση:

$$n \rightarrow n - 1.$$

Ο debug έλεγχος των πρώτων μεταβάσεων είναι ουσιαστικός, διότι επιβεβαιώνει ότι:

- δεν υπάρχει αναχώρηση από κενό σύστημα,
- δεν υπάρχει αποδεκτή άφιξη πέρα από τη χωρητικότητα,
- οι απορρίψεις καταγράφονται σωστά,
- η κατάσταση μένει πάντα στο διάστημα $0 \leq n \leq 10$.

3.5 Time averages και σωστή εκτίμηση μετρικών

Σε event-driven προσομοίωση, οι χρονικές αποστάσεις μεταξύ γεγονότων δεν είναι ίσες. Για αυτό οι εργοδικές πιθανότητες δεν πρέπει να εκτιμώνται απλώς μετρώντας πόσες φορές εμφανίστηκε μια κατάσταση, αλλά με βάση τον χρόνο παραμονής σε κάθε κατάσταση.

Αν T_i είναι ο συνολικός χρόνος που το σύστημα πέρασε στην κατάσταση i , τότε:

$$P_i \approx \frac{T_i}{T_{\text{total}}}.$$

Αντίστοιχα, ο μέσος αριθμός πελατών στο σύστημα προκύπτει ως time average:

$$L \approx \frac{1}{T_{\text{total}}} \int_0^{T_{\text{total}}} n(t) dt.$$

Αυτό είναι σημαντικό θεωρητικό σημείο, γιατί σε continuous-time συστήματα οι καταστάσεις στις οποίες μένει περισσότερο το σύστημα πρέπει να έχουν μεγαλύτερο βάρος.

3.6 State-dependent ρυθμός εξυπηρέτησης

Στο τελευταίο ερώτημα, ο ρυθμός εξυπηρέτησης εξαρτάται από την κατάσταση:

$$\mu_i = \mu(i + 1), \quad i = 1, 2, \dots, 10.$$

Άρα το μοντέλο παραμένει birth-death process, αλλά οι death rates δεν είναι σταθεροί.

Σε κατάσταση $i > 0$, ο συνολικός ρυθμός γεγονότων γίνεται:

$$\lambda + \mu_i = \lambda + \mu(i + 1).$$

Άρα:

$$P(\text{arrival} \mid i) = \frac{\lambda}{\lambda + \mu(i + 1)},$$

και:

$$P(\text{departure} \mid i) = \frac{\mu(i + 1)}{\lambda + \mu(i + 1)}.$$

Επίσης:

$$\Delta t \sim \text{Exp}(\lambda + \mu(i + 1)).$$

Στον κώδικα πρέπει να επανυπολογίζεται ο ρυθμός εξυπηρέτησης κάθε φορά που αλλάζει η κατάσταση. Επίσης απαιτείται προσοχή στις μονάδες. Αν το λ είναι σε πελάτες/min και το μ δοθεί σε πελάτες/sec, πρέπει πρώτα να γίνει μετατροπή.

3.7 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. **Τι σημαίνει $M/M/1/10$;**

Σημαίνει Poisson αφίξεις, εκθετική εξυπηρέτηση, έναν εξυπηρετητή και συνολική χωρητικότητα 10 πελατών.

2. **Ποια είναι η βασική διαφορά $M/M/1$ και $M/M/1/10$;**

Το $M/M/1$ έχει άπειρη χωρητικότητα. Το $M/M/1/10$ έχει πεπερασμένη χωρητικότητα και απορρίπτει αφίξεις όταν γεμίσει.

3. **Γιατί το $M/M/1/10$ έχει στάσιμη κατανομή ακόμη και αν $\lambda > \mu$;**

Επειδή το state space είναι πεπερασμένο. Η κατάσταση δεν μπορεί να ξεπεράσει το 10. Η υπερφόρτωση εμφανίζεται ως blocking, όχι ως άπειρη ουρά.

4. **Ποια είναι η πιθανότητα απόρριψης;**

Είναι η πιθανότητα το σύστημα να βρίσκεται στη μέγιστη χωρητικότητα:

$$P_{\text{rej}} = P_{10}.$$

5. **Γιατί χρησιμοποιούμε λ_{eff} στον νόμο Little;**

Επειδή μόνο οι αποδεκτοί πελάτες εισέρχονται στο σύστημα. Οι απορριπτόμενοι δεν έχουν χρόνο παραμονής στο σύστημα.

6. **Τι είναι transient period;**

Είναι η αρχική περίοδος στην οποία τα αποτελέσματα επηρεάζονται από την αρχική κατάσταση. Συνήθως αφαιρείται για καλύτερη εκτίμηση της στάσιμης συμπεριφοράς.

7. **Γιατί το transient είναι πιο εμφανές σε οριακά φορτισμένα συστήματα;**

Επειδή το σύστημα χρειάζεται περισσότερο χρόνο για να επισκεφθεί αντιπροσωπευτικά όλες τις καταστάσεις. Η αρχική κατάσταση μπορεί να επηρεάσει περισσότερο τις μέσες εκτιμήσεις.

8. **Τι σημαίνει non-terminating simulation;**

Είναι προσομοίωση χωρίς φυσικό τέλος, όπου ενδιαφερόμαστε για μακροχρόνιες μέσες

τιμές και στάσιμες πιθανότητες.

9. Γιατί χρησιμοποιούμε ίδιο seed σε όλα τα runs;

Για αναπαραγωγιμότητα και δίκαιη σύγκριση μεταξύ διαφορετικών σεναρίων.

10. Το ίδιο seed αρκεί για στατιστική αξιοπιστία;

Όχι. Για στατιστική αξιολόγηση χρειάζονται πολλαπλές ανεξάρτητες εκτελέσεις και διαστήματα εμπιστοσύνης.

11. Γιατί σε continuous-time simulation οι πιθανότητες πρέπει να είναι time averages;

Επειδή οι χρόνοι παραμονής στις καταστάσεις δεν είναι ίσοι. Μία κατάσταση στην οποία το σύστημα μένει περισσότερο πρέπει να έχει μεγαλύτερο βάρος.

12. Τι αλλάζει όταν ο ρυθμός εξυπηρέτησης είναι state-dependent;

Ο ρυθμός αναχώρησης δεν είναι σταθερός. Πρέπει να υπολογίζεται σε κάθε κατάσταση ως $\mu_i = \mu(i + 1)$.

13. Ποιο είναι το βασικό λάθος στο state-dependent μοντέλο;

Η ανάμειξη μονάδων. Όλοι οι ρυθμοί πρέπει να είναι στην ίδια μονάδα χρόνου.

14. Πώς επηρεάζει το μεγαλύτερο T την προσομοίωση;

Μειώνει τη στατιστική μεταβλητότητα και βελτιώνει τη σύγκλιση, αλλά αυξάνει τον χρόνο εκτέλεσης.

4 4η Εργαστηριακή Άσκηση: Τηλεφωνικά Κέντρα, M/M/c και Erlang C

4.1 Θεωρητικός πυρήνας της άσκησης

Η 4η εργαστηριακή άσκηση μεταφέρει τη θεωρία ουρών σε εφαρμογή τηλεφωνικού κέντρου. Οι κλήσεις είναι οι πελάτες του συστήματος και οι διαθέσιμοι πόροι, όπως trunks ή agents, είναι οι εξυπηρετητές.

Η άσκηση έχει δύο κύρια μέρη:

1. σχεδιασμό εταιρικού PBX με πολλά trunks,
2. ανάλυση τηλεφωνικού κέντρου Erlang C με στόχο πιθανότητα αναμονής, service level και ASA.

Η κεντρική διάκριση είναι μεταξύ Erlang B και Erlang C.

Erlang B. Το Erlang B είναι blocking model. Αν όλοι οι εξυπηρετητές είναι κατειλημμένοι, η νέα κλήση απορρίπτεται. Δεν υπάρχει ουρά αναμονής. Το βασικό μέγεθος είναι η πιθανότητα απόρριψης.

Erlang C. Το Erlang C είναι queueing model. Αν όλοι οι εξυπηρετητές είναι κατειλημμένοι, η νέα κλήση δεν απορρίπτεται αλλά περιμένει στην ουρά. Δεν υπάρχει εγκατάλειψη. Τα βασικά μεγέθη είναι η πιθανότητα αναμονής, το Service Level και το Average Speed of Answer.

Στην εκφώνηση δηλώνεται ότι, αν μια κλήση δεν μπορεί να εξυπηρετηθεί άμεσα, μπαίνει σε ουρά απείρου μήκους. Άρα το κατάλληλο μοντέλο είναι Erlang C και όχι Erlang B.

4.2 PBX ως σύστημα M/M/c

Στο πρώτο μέρος, το PBX έχει πολλούς παράλληλους εξυπηρετητές, δηλαδή trunks. Αν υπάρχουν c trunks, ο Kendall συμβολισμός είναι:

$$M/M/c/\infty/FCFS.$$

Στην άσκηση, επειδή υπάρχουν 50 trunks, το μοντέλο είναι:

$$M/M/50/\infty/FCFS.$$

Η ερμηνεία είναι:

- το πρώτο M : αφίξεις Poisson,
- το δεύτερο M : εκθετικοί χρόνοι κλήσης,
- το 50: αριθμός παράλληλων trunks,
- το ∞ : άπειρη ουρά, χωρίς απόρριψη,
- το $FCFS$: εξυπηρέτηση με σειρά άφιξης.

Αν n είναι ο αριθμός κλήσεων στο σύστημα, οι ρυθμοί μετάβασης είναι:

$$\lambda_n = \lambda, \quad n \geq 0,$$

και:

$$\mu_n = \begin{cases} n\mu, & 1 \leq n \leq c, \\ c\mu, & n > c. \end{cases}$$

Η ερμηνεία είναι απλή. Όσο υπάρχουν λιγότερες από c κλήσεις, κάθε νέα κλήση ενεργοποιεί έναν επιπλέον εξυπηρετητή, άρα ο συνολικός ρυθμός εξυπηρέτησης είναι $n\mu$. Όταν όμως υπάρχουν τουλάχιστον c κλήσεις, όλοι οι εξυπηρετητές είναι απασχολημένοι και ο συνολικός ρυθμός εξυπηρέτησης δεν μπορεί να ξεπεράσει το $c\mu$.

4.3 Offered load, actual load και utilization

Η προσφερόμενη κίνηση είναι:

$$A = \lambda h = \frac{\lambda}{\mu}.$$

Μετρίεται σε Erlangs. Ένα Erlang σημαίνει φορτίο ισοδύναμο με έναν εξυπηρετητή συνεχώς απασχολημένο.

Το offered load είναι ο μέσος φόρτος που προσφέρεται στο σύστημα από τις αφίξεις. Το actual ή carried load είναι ο φόρτος που τελικά μεταφέρεται από το σύστημα.

Σε σύστημα χωρίς απώλειες και με ευστάθεια, όπως το Erlang C με άπειρη ουρά, ισχύει ποιοτικά:

$$\text{actual load} = \text{offered load}.$$

Αν όμως είχαμε blocking model, τότε ένα μέρος των κλήσεων θα απορριπτόταν και το actual load θα ήταν μικρότερο από το offered load.

Ο βαθμός χρησιμοποίησης σε σύστημα $M/M/c$ είναι:

$$\rho = \frac{A}{c} = \frac{\lambda}{c\mu}.$$

Η συνθήκη ευστάθειας για Erlang C είναι:

$$\rho < 1 \quad \Leftrightarrow \quad \lambda < c\mu.$$

Αν ρ πλησιάσει το 1, οι εξυπηρετητές είναι σχεδόν πάντα απασχολημένοι και η πιθανότητα αναμονής αυξάνεται απότομα. Αν ρ είναι αρκετά κάτω από το 1, το σύστημα έχει περιθώριο να απορροφά τη στοχαστική μεταβλητότητα των αφίξεων.

4.4 Erlang C: πιθανότητα αναμονής, Service Level και ASA

Στο δεύτερο μέρος, το τηλεφωνικό κέντρο μοντελοποιείται ως $M/M/N$ με άπειρη ουρά.

Οι βασικές παραδοχές είναι:

- αφίξεις Poisson,
- εκθετικοί χρόνοι εξυπηρέτησης,
- N παράλληλοι εξυπηρετητές,
- FCFS πειθαρχία,
- άπειρη ουρά,
- καμία εγκατάλειψη πελάτη.

Το offered load είναι:

$$A = \lambda h = \frac{\lambda}{\mu}.$$

Η πιθανότητα μηδενικών κλήσεων στο σύστημα είναι:

$$P_0 = \left[\sum_{k=0}^{N-1} \frac{A^k}{k!} + \frac{A^N}{N!} \frac{N}{N-A} \right]^{-1}.$$

Η πιθανότητα μια νέα κλήση να χρειαστεί να περιμένει είναι:

$$P_w = \frac{A^N}{N!} \frac{N}{N-A} P_0.$$

Αυτό είναι το βασικό μέγεθος του Erlang C. Δεν μετρά πιθανότητα απόρριψης, αλλά πιθανότητα αναμονής. Δηλαδή:

$$P_w = P(\text{όλοι οι agents είναι απασχολημένοι όταν φτάνει η κλήση}).$$

Το Service Level σε χρονικό όριο t είναι:

$$SL(t) = 1 - P_w e^{-(N\mu - \lambda)t}.$$

Εκφράζει το ποσοστό των κλήσεων που απαντώνται μέσα σε χρόνο t . Σε τηλεφωνικά κέντρα, τυπικός στόχος είναι το 80/20, δηλαδή 80% των κλήσεων να απαντώνται μέσα σε 20 sec.

Ο μέσος χρόνος απάντησης, Average Speed of Answer, είναι:

$$ASA = \frac{P_w h}{N - A}.$$

Το ASA είναι μέσος χρόνος αναμονής μέχρι να απαντηθεί η κλήση. Όσο μικρότερο είναι το P_w και όσο μεγαλύτερο είναι το πλεόνασμα εξυπηρετικής ικανότητας $N - A$, τόσο μικρότερο είναι το ASA .

4.5 Ποιοτική ερμηνεία Erlang C

Το Erlang C χρησιμοποιείται κυρίως για διαστασιολόγηση τηλεφωνικών κέντρων. Δεν αρκεί να γνωρίζουμε μόνο ότι το σύστημα είναι ευσταθές. Πρέπει να γνωρίζουμε αν προσφέρει αποδεκτή ποιότητα εξυπηρέτησης.

Η βασική αλληλουχία είναι:

$$A \uparrow \Rightarrow \rho \uparrow \Rightarrow P_w \uparrow \Rightarrow ASA \uparrow \Rightarrow SL(t) \downarrow .$$

Δηλαδή, όσο αυξάνεται το φορτίο ή μειώνεται ο αριθμός εξυπηρετητών:

- αυξάνεται το occupancy,
- αυξάνεται η πιθανότητα αναμονής,
- αυξάνεται ο μέσος χρόνος απάντησης,
- μειώνεται το service level.

Το σημαντικό είναι ότι ένα μέτριο average load δεν εγγυάται μηδενική αναμονή. Ακόμη και αν το σύστημα έχει αρκετούς agents κατά μέσο όρο, η τυχαιότητα των αφίξεων και των χρόνων εξυπηρέτησης μπορεί να προκαλέσει στιγμιαίες ουρές. Αυτός είναι ο λόγος που χρησιμοποιείται το Erlang C αντί για έναν απλό μέσο υπολογισμό.

4.6 Πρακτική διάσταση: staffing, occupancy και shrinkage

Στην άσκηση δίνεται ο αριθμός των εξυπηρετητών. Στην πράξη, όμως, συχνά γίνεται το αντίστροφο: δίνεται ένας στόχος Service Level και ζητείται ο ελάχιστος αριθμός agents που τον ικανοποιεί.

Η πρακτική διαδικασία είναι:

1. υπολογίζουμε το offered load:

$$A = \lambda h,$$

2. επιλέγουμε στόχο Service Level, π.χ. 80/20,
3. δοκιμάζουμε διαφορετικές τιμές του N ,

4. βρίσκουμε τον μικρότερο N που ικανοποιεί το service level,
5. ελέγχουμε αν το occupancy είναι αποδεκτό,
6. διορθώνουμε με shrinkage.

Το occupancy είναι:

$$\rho = \frac{A}{N}.$$

Αν είναι πολύ υψηλό, οι agents λειτουργούν κοντά στα όριά τους. Αυτό μπορεί να είναι ανεπιθύμητο ακόμη και αν το service level φαίνεται τυπικά αποδεκτό.

Το shrinkage εκφράζει το ποσοστό του προσωπικού που δεν είναι διαθέσιμο για παραγωγική εξυπηρέτηση λόγω αδειών, ασθένειας, εκπαίδευσης, meetings ή άλλων δραστηριοτήτων. Αν ο καθαρά απαιτούμενος αριθμός agents είναι N_{raw} και το shrinkage είναι s , τότε ο προγραμματισμένος αριθμός agents πρέπει να είναι:

$$N_{\text{scheduled}} = \frac{N_{\text{raw}}}{1 - s}.$$

Άρα το Erlang C δίνει τον απαιτούμενο αριθμό παραγωγικά διαθέσιμων agents, αλλά στην πράξη πρέπει να προγραμματιστούν περισσότεροι.

4.7 Erlang A και εγκατάλειψη ουράς

Το Erlang C υποθέτει ότι κανένας πελάτης δεν εγκαταλείπει την ουρά. Αυτό είναι συχνά μη ρεαλιστικό. Στην πράξη, αν ένας πελάτης περιμένει πολλή ώρα, μπορεί να εγκαταλείψει. Αυτό ονομάζεται abandonment ή reneging.

Το Erlang A μοντελοποιεί αυτή την περίπτωση. Συμβολίζεται συχνά ως:

$$M/M/N + M.$$

Το επιπλέον $+M$ δηλώνει εκθετικό χρόνο υπομονής πριν την εγκατάλειψη. Το Erlang A είναι πιο ρεαλιστικό για call centers, αλλά πιο σύνθετο από το Erlang C.

4.8 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. Τι μοντελοποιούμε ως πελάτες και τι ως εξυπηρετητές σε τηλεφωνικό κέντρο;

Οι κλήσεις είναι οι πελάτες. Τα trunks ή οι agents είναι οι εξυπηρετητές.

2. Ποιος είναι ο Kendall τύπος του PBX με 50 trunks και άπειρη ουρά;

$$M/M/50/\infty/FCFS.$$

Οι αφίξεις είναι Poisson, οι χρόνοι κλήσης εκθετικοί, υπάρχουν 50 παράλληλοι εξυπηρετητές, άπειρη ουρά και FCFS εξυπηρέτηση.

3. Ποια είναι η διαφορά Erlang B και Erlang C;

Το Erlang B είναι blocking model: αν όλοι οι εξυπηρετητές είναι κατειλημμένοι, η κλήση απορρίπτεται. Το Erlang C είναι queueing model: η κλήση περιμένει στην ουρά.

4. Γιατί στην άσκηση χρησιμοποιούμε Erlang C και όχι Erlang B;

Επειδή η εκφώνηση λέει ότι οι κλήσεις που δεν εξυπηρετούνται άμεσα μπαίνουν σε ουρά και δεν χάνονται.

5. Τι είναι offered load;

Είναι ο μέσος φόρτος που προσφέρεται στο σύστημα:

$$A = \lambda h = \frac{\lambda}{\mu}.$$

Μετριέται σε Erlangs.

6. Τι σημαίνει 1 Erlang;

Σημαίνει φορτίο ισοδύναμο με έναν εξυπηρετητή συνεχώς απασχολημένο.

7. Ποια είναι η διαφορά offered load και actual load;

Offered load είναι ο φόρτος που προσφέρεται στο σύστημα. Actual ή carried load είναι ο φόρτος που τελικά εξυπηρετείται. Σε σύστημα χωρίς απώλειες και με ευστάθεια συμπίπτουν. Σε blocking σύστημα το actual load είναι μικρότερο.

8. **Τι είναι occupancy;**

Είναι ο βαθμός απασχόλησης των εξυπηρετητών:

$$\rho = \frac{A}{N} = \frac{\lambda}{N\mu}.$$

9. **Ποια είναι η συνθήκη ευστάθειας για Erlang C;**

$$\rho < 1 \quad \Leftrightarrow \quad \lambda < N\mu.$$

Αν δεν ισχύει, η ουρά μεγαλώνει χωρίς όριο.

10. **Τι μετρά η πιθανότητα P_w στο Erlang C;**

Μετρά την πιθανότητα μια νέα κλήση να χρειαστεί να περιμένει, δηλαδή να βρει όλους τους εξυπηρετητές απασχολημένους.

11. **Το P_w είναι πιθανότητα απόρριψης;**

Όχι. Στο Erlang C δεν υπάρχει απόρριψη. Το P_w είναι πιθανότητα αναμονής.

12. **Τι είναι Service Level;**

Είναι το ποσοστό των κλήσεων που απαντώνται μέσα σε συγκεκριμένο χρονικό όριο t :

$$SL(t) = 1 - P_w e^{-(N\mu - \lambda)t}.$$

13. **Τι σημαίνει στόχος 80/20;**

Σημαίνει ότι το 80% των κλήσεων πρέπει να απαντάται μέσα σε 20 δευτερόλεπτα.

14. **Τι είναι ASA;**

Το Average Speed of Answer είναι ο μέσος χρόνος αναμονής μέχρι να απαντηθεί μια κλήση:

$$ASA = \frac{P_w h}{N - A}.$$

15. **Πώς επηρεάζει το occupancy το Service Level;**

Όσο αυξάνεται το occupancy, αυξάνεται η πιθανότητα αναμονής και μειώνεται το Service Level.

16. **Γιατί δεν αρκεί να σχεδιάζουμε μόνο με βάση τον μέσο φόρτο;**

Επειδή οι αφίξεις και οι χρόνοι εξυπηρέτησης είναι τυχαίοι. Ακόμη και αν ο μέσος φόρτος είναι μικρός, μπορούν να δημιουργηθούν στιγμιαίες ουρές.

17. **Τι είναι shrinkage;**

Είναι το ποσοστό προσωπικού που δεν είναι διαθέσιμο για εξυπηρέτηση λόγω αδειών, breaks, training, meetings ή άλλων δραστηριοτήτων.

18. **Πώς διορθώνουμε τον αριθμό agents με shrinkage;**

Αν χρειάζονται N_{raw} παραγωγικά διαθέσιμοι agents και το shrinkage είναι s , τότε:

$$N_{\text{scheduled}} = \frac{N_{\text{raw}}}{1 - s}.$$

19. **Τι είναι Erlang A;**

Είναι μοντέλο που επιτρέπει εγκατάλειψη της ουράς. Συμβολίζεται ως $M/M/N + M$ και είναι πιο ρεαλιστικό όταν οι πελάτες δεν περιμένουν απεριόριστα.

20. **Ποια είναι η βασική παγίδα στην 4η άσκηση;**

Να μπερδέψουμε Erlang B με Erlang C. Αν οι κλήσεις απορρίπτονται, έχουμε Erlang B. Αν περιμένουν στην ουρά, έχουμε Erlang C.

5 5η Εργαστηριακή Άσκηση: Προσομοίωση Διακριτών Γεγονότων και Ανοικτά Δίκτυα Jackson

5.1 Θεωρητικός πυρήνας της άσκησης

Η 5η εργαστηριακή άσκηση αποτελείται από δύο διακριτά αλλά συνδεδεμένα μέρη:

1. προσομοίωση διακριτών γεγονότων ενός web server με εργασίες δύο φάσεων,
2. αναλυτική μελέτη ανοικτού δικτύου ουρών αναμονής με χρήση του θεωρήματος Jackson.

Το πρώτο μέρος εστιάζει στη μεθοδολογία της προσομοίωσης: πώς περιγράφουμε την κατάσταση ενός συστήματος, πώς προχωρά ο χρόνος από γεγονός σε γεγονός, πώς μετράμε σωστά χρονικά μέσα μεγέθη και πώς ελέγχουμε τη στασιμότητα.

Το δεύτερο μέρος εστιάζει στην αναλυτική μελέτη δικτύων ουρών: πώς βρίσκουμε τους effective arrival rates σε κάθε κόμβο, πώς ελέγχουμε την εργοδικότητα, πώς υπολογίζουμε τον μέσο αριθμό πελατών και πώς εντοπίζουμε τη στενωπό του δικτύου.

Η άσκηση συνδέει πρακτικά τρεις βασικές ιδέες του μαθήματος:

- την προσομοίωση διακριτών γεγονότων,
- τον νόμο του Little,
- το θεώρημα Jackson για ανοικτά δίκτυα ουρών.

5.2 Προσομοίωση διακριτών γεγονότων του Web Server

Στο πρώτο μέρος μελετάται ένας single-server FIFO web server. Κάθε request δεν εξυπηρετείται με μία μόνο εργασία, αλλά με δύο διαδοχικές φάσεις:

Request $\rightarrow$ Type-1 job $\rightarrow$ Type-2 job $\rightarrow$ Departure.

Η κρίσιμη λεπτομέρεια είναι ότι, όταν ολοκληρωθεί η εργασία τύπου 1, η εργασία τύπου 2 δεν εξυπηρετείται αναγκαστικά αμέσως. Αντίθετα, τοποθετείται στο τέλος της ίδιας FIFO ουράς. Άρα οι δύο φάσεις του ίδιου request μπορούν να παρεμβληθούν με εργασίες άλλων requests.

Οι αφίξεις των requests ακολουθούν διαδικασία Poisson με ρυθμό λ requests/sec. Επειδή η προσομοίωση δουλεύει σε milliseconds, ο μέσος χρόνος μεταξύ αφίξεων είναι:

$$E[A] = \frac{1000}{\lambda} \text{ ms.}$$

Οι χρόνοι εξυπηρέτησης είναι:

$$S_1 \sim \text{LogNormal}(1, 1),$$

και:

$$S_2 \sim U(0.5, 1).$$

Για τη λογαριθμοκανονική κατανομή ισχύει:

$$E[S_1] = e^{\mu + \sigma^2/2}.$$

Άρα το μέσο συνολικό έργο που εισάγει κάθε request στον server είναι:

$$E[S] = E[S_1] + E[S_2].$$

Το σύστημα είναι ουσιαστικά ένας single-server work-conserving μηχανισμός. Αυτό σημαίνει ότι, αν υπάρχουν εργασίες στην ουρά, ο server δεν μένει αδρανής.

5.3 Δομή της DES προσομοίωσης

Η προσομοίωση είναι discrete event simulation. Ο χρόνος δεν προχωρά με σταθερό βήμα, αλλά πηδά από event σε event.

Στο συγκεκριμένο μοντέλο υπάρχουν τρεις τύποι γεγονότων:

1. **ARRIVAL**: φτάνει νέο request και δημιουργείται εργασία τύπου 1.
2. **DEPART1**: ολοκληρώνεται εργασία τύπου 1 και δημιουργείται εργασία τύπου 2.
3. **DEPART2**: ολοκληρώνεται εργασία τύπου 2 και το request αποχωρεί από το σύστημα.

Η κατάσταση του συστήματος πρέπει να περιλαμβάνει ό,τι είναι απαραίτητο για τη συνέχιση της προσομοίωσης:

- τον τρέχοντα χρόνο,
- αν ο server είναι busy ή idle,
- το job που εξυπηρετείται,
- τη FIFO ουρά,
- τους χρόνους άφιξης των requests,
- τους μετρητές αφίξεων και ολοκληρώσεων,
- τα logs για τους αριθμούς εργασιών τύπου 1 και τύπου 2.

Η βασική αρχή είναι ότι η ουρά αλλάζει μόνο σε event times. Μεταξύ δύο γεγονότων, το πλήθος εργασιών παραμένει σταθερό.

5.4 Στασιμότητα του Web Server

Για να είναι το σύστημα στάσιμο, ο μέσος ρυθμός εισερχόμενου έργου πρέπει να είναι μικρότερος από την εξυπηρετική ικανότητα του server.

Κάθε request απαιτεί κατά μέσο όρο:

$$E[S_1] + E[S_2]$$

milliseconds εξυπηρέτησης. Άρα ο βαθμός φόρτου είναι:

$$\rho = \frac{\lambda (E[S_1] + E[S_2])}{1000}.$$

Η συνθήκη στασιμότητας είναι:

$$\rho < 1.$$

Ισοδύναμα:

$$\lambda < \frac{1000}{E[S_1] + E[S_2]}.$$

Αν $\rho < 1$, ο server μπορεί μακροπρόθεσμα να εξυπηρετεί το εισερχόμενο έργο και η ουρά διαχυμαίνεται γύρω από πεπερασμένες τιμές. Αν $\rho \geq 1$, η ουρά δεν έχει στάσιμη κατανομή και παρουσιάζει μακροχρόνια αυξητική τάση.

Το σημαντικό σημείο δεν είναι μόνο ότι η ουρά μεγαλώνει όταν αυξάνεται το λ , αλλά ότι υπάρχει συγκεκριμένο θεωρητικό όριο πέρα από το οποίο το σύστημα δεν είναι πια στάσιμο.

5.5 Χρονικά σταθμισμένοι μέσοι όροι

Ένα από τα πιο σημαντικά θεωρητικά σημεία της άσκησης είναι ότι οι μέσοι αριθμοί εργασιών δεν πρέπει να υπολογίζονται ως απλοί αριθμητικοί μέσοι των τιμών στα event times.

Αν $Q(t)$ είναι το πλήθος εργασιών στο σύστημα, τότε είναι βηματική συνάρτηση. Κάθε τιμή του $Q(t)$ διατηρείται για διαφορετική χρονική διάρκεια. Επομένως, η σωστή εκτίμηση του μέσου είναι time-weighted:

$$\bar{Q} = \frac{\sum_i Q(t_i) \Delta t_i}{\sum_i \Delta t_i}, \quad \Delta t_i = t_{i+1} - t_i.$$

Ο απλός μέσος:

$$\frac{1}{n} \sum_i Q(t_i)$$

είναι γενικά λάθος, επειδή αντιμετωπίζει όλα τα δείγματα ως ισοδύναμα, παρότι ένα state μπορεί να κράτησε πολύ περισσότερο από ένα άλλο.

Αυτό ισχύει και για τον νόμο του Little. Το N στη σχέση:

$$N = \lambda R$$

είναι χρονικά σταθμισμένος μέσος αριθμός εργασιών στο σύστημα, όχι απλός μέσος στιγμιотύπων.

5.6 Μεταβατική περίοδος και μέθοδος MQS

Η προσομοίωση ξεκινά από άδειο σύστημα. Όμως, σε μόνιμη λειτουργία, ένας web server δεν βρίσκεται απαραίτητα αρχικά άδειος. Άρα το αρχικό τμήμα της προσομοίωσης είναι μεταβατικό και μπορεί να δημιουργήσει μεροληψία.

Η μέθοδος MQS χρησιμοποιείται για να εντοπιστεί περίπου πότε η προσομοίωση μπαίνει σε steady state. Ορίζουμε:

$$MQS(t) = \frac{1}{t} \int_0^t Q(s) ds.$$

Το $MQS(t)$ είναι running time-weighted average του μεγέθους της ουράς. Αρχικά επηρεάζεται έντονα από την αρχική κατάσταση, αλλά στη συνέχεια τείνει να σταθεροποιείται γύρω από τη μόνιμη μέση τιμή.

Η πρακτική διαδικασία είναι:

1. τρέχουμε ένα pilot run,
2. σχεδιάζουμε το $MQS(t)$,
3. εντοπίζουμε από ποιο σημείο και μετά η καμπύλη δεν έχει συστηματική τάση,
4. αφαιρούμε το αρχικό τμήμα πριν από αυτό το cutoff,
5. επανυπολογίζουμε τις μετρικές μόνο μετά το cutoff.

Η αφαίρεση transient δεν εγγυάται πάντα μικρότερο διάστημα εμπιστοσύνης. Μπορεί να μειώνει τη μεροληψία, αλλά ταυτόχρονα μειώνει και το διαθέσιμο δείγμα. Άρα υπάρχει trade-off ανάμεσα στη μείωση bias και στην αύξηση variance.

5.7 Διαστήματα εμπιστοσύνης και ανεξάρτητες επαναλήψεις

Για να υπολογίσουμε confidence intervals, δεν χρησιμοποιούμε όλα τα διαδοχικά δείγματα $Q(t)$ από ένα run ως ανεξάρτητα δείγματα. Οι τιμές μέσα στο ίδιο run είναι αυτοσυσχετισμένες. Αν η ουρά έχει μεγάλη τιμή σε μία στιγμή, είναι πιθανό να έχει κοντινή τιμή και λίγο αργότερα.

Για αυτό η άσκηση χρησιμοποιεί $n \geq 30$ ανεξάρτητες επαναλήψεις. Κάθε επανάληψη δίνει έναν συνοπτικό αριθμό, για παράδειγμα:

$$Y_k = \frac{1}{T_k} \int_0^{T_k} Q_k(s) ds.$$

Οι τιμές:

$$Y_1, Y_2, \dots, Y_n$$

θεωρούνται ανεξάρτητες, εφόσον προκύπτουν από ανεξάρτητα runs. Σε αυτές βασίζονται τα confidence intervals.

Για τη μέση τιμή χρησιμοποιείται διάστημα της μορφής:

$$\bar{Y} \pm t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}}.$$

Για τη διάμεσο χρησιμοποιείται διάστημα βασισμένο σε στατιστικές τάξης. Το διάστημα για τη διάμεσο είναι λιγότερο εξαρτημένο από υποθέσεις κανονικότητας, ενώ το διάστημα για τη μέση τιμή βασίζεται στη συμπεριφορά του δειγματικού μέσου.

Όσο το σύστημα πλησιάζει το $\rho = 1$, τόσο αυξάνεται η μεταβλητότητα από run σε run. Άρα τα confidence intervals γίνονται πλατύτερα και χρειάζονται περισσότερες ή μεγαλύτερες επαναλήψεις για σταθερότερες εκτιμήσεις.

5.8 Επαλήθευση του νόμου Little

Ο νόμος του Little στη μορφή της άσκησης είναι:

$$N = \lambda R.$$

Εδώ:

- λ είναι ο εξωτερικός ρυθμός άφιξης των requests,
- R είναι ο μέσος end-to-end response time ενός request,
- N είναι ο χρονικά σταθμισμένος μέσος αριθμός εργασιών στο σύστημα.

Χρειάζεται προσοχή στις μονάδες. Αν λ είναι σε requests/sec και R σε milliseconds, πρέπει να χρησιμοποιηθεί:

$$\lambda_{\text{ms}} = \frac{\lambda}{1000}.$$

Άρα:

$$N \approx \frac{\lambda}{1000} R.$$

Ο νόμος του Little λειτουργεί και ως έλεγχος συνέπειας της προσομοίωσης, επειδή συνδέει τρεις ποσότητες που υπολογίζονται με διαφορετικό τρόπο: ρυθμό άφιξης, μέσο response time και time-weighted mean number.

5.9 Ανοικτό δίκτυο ουρών Jackson

Στο δεύτερο μέρος μελετάται ανοικτό δίκτυο ουρών με πέντε κόμβους:

$$Q_1, Q_2, Q_3, Q_4, Q_5.$$

Το δίκτυο είναι ανοικτό επειδή υπάρχουν εξωτερικές αφίξεις και πελάτες μπορούν να αποχωρήσουν από το δίκτυο μετά από κάποια εξυπηρέτηση.

Για να εφαρμοστεί το θεώρημα Jackson, απαιτούνται οι εξής παραδοχές:

- οι εξωτερικές αφίξεις είναι Poisson,
- οι χρόνοι εξυπηρέτησης σε κάθε κόμβο είναι εκθετικοί,
- κάθε κόμβος έχει έναν εξυπηρετητή,
- οι ουρές έχουν άπειρη χωρητικότητα,
- οι δρομολογήσεις γίνονται με σταθερές πιθανότητες,
- οι πιθανότητες δρομολόγησης δεν εξαρτώνται από την κατάσταση του δικτύου,
- οι εξυπηρετήσεις και οι δρομολογήσεις είναι ανεξάρτητες,
- για κάθε κόμβο ισχύει $\rho_i < 1$.

Αν οι παραδοχές ισχύουν και το δίκτυο είναι εργοδικό, τότε η μόνιμη κατανομή έχει μορφή γινομένου. Δηλαδή, το δίκτυο μπορεί να αναλυθεί σαν σύνολο ανεξάρτητων $M/M/1$ ουρών με effective arrival rates.

5.10 Εξισώσεις ροής και effective arrival rates

Το πρώτο βήμα σε ένα ανοικτό δίκτυο Jackson είναι να βρεθεί ο συνολικός ρυθμός άφιξης σε κάθε ουρά. Αυτός δεν είναι απαραίτητα ίσος με τον εξωτερικό ρυθμό άφιξης, διότι ένας κόμβος μπορεί να δέχεται και εσωτερική ροή από άλλους κόμβους.

Η γενική εξίσωση ροής είναι:

$$\Gamma_j = \gamma_j + \sum_i r_{ij} \Gamma_i,$$

όπου:

- Γ_j είναι ο συνολικός ρυθμός άφιξης στον κόμβο j ,
- γ_j είναι ο εξωτερικός ρυθμός άφιξης στον κόμβο j ,
- r_{ij} είναι η πιθανότητα μετάβασης από τον κόμβο i στον κόμβο j .

Αφού βρεθούν οι Γ_i , οι εντάσεις φορτίου είναι:

$$\rho_i = \frac{\Gamma_i}{\mu_i}.$$

Η συνθήκη εργοδικότητας του δικτύου είναι:

$$\rho_i < 1, \quad \forall i.$$

Αν έστω ένας κόμβος έχει $\rho_i \geq 1$, τότε το δίκτυο δεν είναι εργοδικό. Αυτό συμβαίνει γιατί η συγκεκριμένη ουρά δεν μπορεί να εξυπηρετήσει το έργο που δέχεται και τελικά δημιουργεί αστάθεια στο συνολικό δίκτυο.

5.11 Μέσος αριθμός πελατών και end-to-end καθυστέρηση

Υπό τις παραδοχές Jackson, κάθε κόμβος αναλύεται σαν $M/M/1$. Άρα για κάθε ουρά:

$$E[N_i] = \frac{\rho_i}{1 - \rho_i}.$$

Ο συνολικός μέσος αριθμός πελατών στο δίκτυο είναι:

$$E[N] = \sum_i E[N_i].$$

Αν ο συνολικός εξωτερικός ρυθμός εισόδου στο δίκτυο είναι:

$$\gamma = \sum_i \gamma_i,$$

τότε από τον νόμο του Little:

$$E[T] = \frac{E[N]}{\gamma}.$$

Το $E[T]$ είναι ο μέσος end-to-end χρόνος παραμονής ενός πελάτη στο δίκτυο, από την είσοδο μέχρι την τελική έξοδο.

5.12 Στενωπός και μέγιστος ρυθμός εισόδου

Η στενωπός του δικτύου δεν είναι απαραίτητα η ουρά με το μικρότερο μ_i . Είναι η ουρά με το μεγαλύτερο:

$$\rho_i = \frac{\Gamma_i}{\mu_i}.$$

Αυτό είναι κρίσιμο. Μια ουρά με σχετικά μεγάλο μ_i μπορεί να είναι στενωπός αν δέχεται πολύ μεγάλη εσωτερική ροή. Αντίθετα, μια ουρά με μικρό μ_i μπορεί να μην είναι πρόβλημα αν δέχεται μικρή ροή.

Για να βρούμε τη μέγιστη επιτρεπτή τιμή μιας εξωτερικής παραμέτρου, όπως το λ_1 , εκφράζουμε κάθε Γ_i ως συνάρτηση του λ_1 και απαιτούμε:

$$\Gamma_i < \mu_i, \quad \forall i.$$

Κάθε ουρά δίνει ένα άνω φράγμα για το λ_1 . Το μικρότερο από αυτά τα φράγματα είναι το πραγματικό μέγιστο επιτρεπτό:

$$\lambda_{1,\max} = \min_i \{\text{φράγμα από } Q_i\}.$$

Η ουρά που δίνει το αυστηρότερο φράγμα είναι η limiting queue.

Καθώς το λ_1 πλησιάζει το $\lambda_{1,\max}$, η αντίστοιχη στενωπός έχει:

$$\rho_i \rightarrow 1.$$

Τότε:

$$E[N_i] = \frac{\rho_i}{1 - \rho_i} \rightarrow \infty,$$

οπότε και ο end-to-end χρόνος καθυστέρησης αυξάνεται απότομα. Αυτό εξηγεί την εκρηκτική μορφή του διαγράμματος καθυστέρησης κοντά στο όριο εργοδικότητας.

5.13 Ποιοτικά συμπεράσματα

Η 5η άσκηση δείχνει ότι η προσομοίωση και η αναλυτική θεωρία ουρών συμπληρώνουν η μία την άλλη.

Στο πρώτο μέρος, η προσομοίωση είναι απαραίτητη επειδή το σύστημα έχει γενικές κατανομές εξυπηρέτησης και δομή δύο φάσεων. Εκεί η βασική προσοχή δίνεται σε:

- σωστή DES υλοποίηση,
- σωστή σειρά FIFO,
- σωστά time-weighted averages,
- αφαίρεση transient,
- ανεξάρτητες επαναλήψεις για confidence intervals,
- επαλήθευση με τον νόμο Little.

Στο δεύτερο μέρος, το θεώρημα Jackson επιτρέπει αναλυτική λύση του δικτύου, αρκεί να ισχύουν οι παραδοχές του. Η βασική διαδικασία είναι:

$$\text{routing} \rightarrow \Gamma_i \rightarrow \rho_i \rightarrow E[N_i] \rightarrow E[T].$$

Το σημαντικότερο ποιοτικό συμπέρασμα είναι ότι η συνολική καθυστέρηση ενός δικτύου επηρεάζεται δυσανάλογα από την ουρά που πλησιάζει περισσότερο τον κορεσμό.

5.14 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. Τι είναι προσομοίωση διακριτών γεγονότων;

Είναι προσομοίωση όπου ο χρόνος προχωρά από γεγονός σε γεγονός και όχι με σταθερό χρονικό βήμα. Η κατάσταση αλλάζει μόνο στις χρονικές στιγμές γεγονότων.

2. Ποια είναι τα τρία βασικά στοιχεία μιας DES προσομοίωσης;

Τα γεγονότα, η κατάσταση του συστήματος και η καταγραφή μετρικών. Τα γεγονότα καθορίζουν τι μπορεί να συμβεί, η κατάσταση περιγράφει τι ισχύει τώρα, και τα logs επιτρέπουν τον υπολογισμό των αποτελεσμάτων.

3. Ποια είναι τα events στο web server μοντέλο;

Τα events είναι ARRIVAL, DEPART1 και DEPART2. Η άφιξη δημιουργεί type-1 job, το DEPART1 δημιουργεί type-2 job, και το DEPART2 ολοκληρώνει το request.

4. Γιατί οι δύο φάσεις του ίδιου request δεν εκτελούνται απαραίτητα διαδοχικά;

Επειδή η type-2 εργασία μπαίνει στο τέλος της FIFO ουράς. Αν υπάρχουν ήδη άλλες εργασίες, προηγούνται αυτές.

5. Ποια είναι η συνθήκη στασιμότητας του web server;

Η συνθήκη είναι:

$$\rho = \frac{\lambda(E[S_1] + E[S_2])}{1000} < 1.$$

Δηλαδή ο μέσος εισερχόμενος φόρτος πρέπει να είναι μικρότερος από την ικανότητα του server.

6. Τι συμβαίνει αν $\rho \geq 1$;

Η ουρά δεν έχει στάσιμη κατανομή και εμφανίζει μακροχρόνια αυξητική τάση. Ο server δεν προλαβαίνει να εξυπηρετήσει το εισερχόμενο έργο.

7. Γιατί χρησιμοποιούμε time-weighted averages;

Επειδή οι τιμές της ουράς κρατούν για άνισες χρονικές διάρκειες. Μία τιμή που διαρκεί περισσότερο πρέπει να επηρεάζει περισσότερο τον μέσο.

8. Ποιο είναι το λάθος με τον απλό μέσο των τιμών στα event times;

Θεωρεί όλα τα δείγματα ισοδύναμα, σαν να είχαν ληφθεί σε ίσα χρονικά διαστήματα. Αυτό δεν ισχύει σε DES.

9. Τι είναι transient period;

Είναι η αρχική περίοδος όπου η προσομοίωση επηρεάζεται από την αρχική κατάσταση και δεν αντιπροσωπεύει ακόμη τη μόνιμη λειτουργία.

10. Τι είναι η μέθοδος MQS;

Είναι η μέθοδος όπου υπολογίζουμε το running time-weighted mean queue size:

$$MQS(t) = \frac{1}{t} \int_0^t Q(s) ds.$$

Το χρησιμοποιούμε για να εντοπίσουμε πότε η προσομοίωση φαίνεται να σταθεροποιείται.

11. Γιατί η αφαίρεση transient δεν μειώνει πάντα το πλάτος του confidence interval;

Επειδή αφαιρώντας δεδομένα μειώνουμε τη μεροληψία, αλλά χρησιμοποιούμε λιγότερο δείγμα. Αυτό μπορεί να αυξήσει τη διακύμανση της εκτίμησης.

12. Γιατί χρειάζονται πολλές ανεξάρτητες επαναλήψεις για confidence intervals;

Επειδή οι διαδοχικές τιμές μέσα σε ένα run είναι αυτοσυσχετισμένες. Αντίθετα, οι συνοπτικοί μέσοι από ανεξάρτητα runs μπορούν να χρησιμοποιηθούν ως ανεξάρτητα δείγματα.

13. Τι ελέγχει ο νόμος του Little στην προσομοίωση;

Ελέγχει τη συνέπεια μεταξύ ρυθμού άφιξης, μέσου response time και μέσου αριθμού εργασιών:

$$N = \lambda R.$$

14. Γιατί χρειάζεται προσοχή στις μονάδες στον νόμο Little;

Επειδή το λ μπορεί να είναι σε requests/sec ενώ το R σε ms. Πρέπει να μετατραπεί το ένα μέγεθος ώστε οι μονάδες να είναι συμβατές.

15. Τι είναι ανοικτό δίκτυο ουρών;

Είναι δίκτυο στο οποίο πελάτες εισέρχονται από εξωτερικές πηγές, μετακινούνται μεταξύ ουρών και τελικά αποχωρούν από το δίκτυο.

16. Ποιες είναι οι βασικές παραδοχές του θεωρήματος Jackson;

Poisson εξωτερικές αφίξεις, εκθετικοί ανεξάρτητοι χρόνοι εξυπηρέτησης, σταθερές πιθανότητες δρομολόγησης, άπειρες ουρές και εργοδικότητα σε κάθε κόμβο.

17. Τι σημαίνει ότι η στάσιμη κατανομή έχει μορφή γινομένου;

Σημαίνει ότι το δίκτυο μπορεί να αναλυθεί σαν γινόμενο ανεξάρτητων $M/M/1$ ουρών, καθεμία με τον δικό της effective arrival rate.

18. Πώς βρίσκουμε τον effective arrival rate σε κάθε κόμβο;

Γράφουμε εξισώσεις ισορροπίας ροής:

$$\Gamma_j = \gamma_j + \sum_i r_{ij} \Gamma_i.$$

19. Ποια είναι η συνθήκη εργοδικότητας σε ανοικτό Jackson δίκτυο;

Πρέπει για κάθε ουρά:

$$\rho_i = \frac{\Gamma_i}{\mu_i} < 1.$$

20. Πώς υπολογίζεται ο μέσος αριθμός πελατών σε κάθε ουρά;

Επειδή κάθε κόμβος είναι $M/M/1$:

$$E[N_i] = \frac{\rho_i}{1 - \rho_i}.$$

21. Πώς βρίσκουμε τον end-to-end μέσο χρόνο καθυστέρησης;

Υπολογίζουμε πρώτα:

$$E[N] = \sum_i E[N_i],$$

και μετά από τον νόμο Little:

$$E[T] = \frac{E[N]}{\gamma},$$

όπου γ είναι ο συνολικός εξωτερικός ρυθμός εισόδου.

22. Ποια ουρά είναι η στενωπός;

Η ουρά με το μεγαλύτερο ρ_i , όχι απαραίτητα αυτή με το μικρότερο μ_i .

23. Γιατί η στενωπός δεν είναι πάντα η ουρά με το μικρότερο service rate;

Επειδή σημασία έχει ο λόγος ροής προς ρυθμό εξυπηρέτησης:

$$\rho_i = \frac{\Gamma_i}{\mu_i}.$$

Μια ουρά με μεγάλο μ_i μπορεί να είναι στενωπός αν δέχεται πολύ μεγάλη ροή.

24. Πώς βρίσκουμε τη μέγιστη επιτρεπτή τιμή ενός εξωτερικού ρυθμού;

Εκφράζουμε κάθε Γ_i ως συνάρτηση του εξωτερικού ρυθμού και απαιτούμε $\Gamma_i < \mu_i$ για όλες τις ουρές. Το αυστηρότερο φράγμα καθορίζει το μέγιστο.

25. Γιατί η καθυστέρηση εκρήγνυται κοντά στο όριο εργοδικότητας;

Επειδή για τη στενωπό:

$$E[N_i] = \frac{\rho_i}{1 - \rho_i}.$$

Όταν $\rho_i \rightarrow 1$, ο παρονομαστής τείνει στο μηδέν και ο μέσος αριθμός πελατών αυξάνεται απότομα.

6 6η Εργαστηριακή Άσκηση: Πρόβλεψη Χρονοσειράς Φόρτου

6.1 Στόχος της άσκησης

Η 6η εργαστηριακή άσκηση αφορά την πρόβλεψη χρονοσειράς φόρτου, με εφαρμογή σε πραγματικά δεδομένα από data centers. Η χρονοσειρά περιγράφει τον αριθμό υπολογιστικών πόρων GPU που ζητούνται ανά ώρα από εργασίες που φτάνουν στο σύστημα.

Η σύνδεση με τα συστήματα αναμονής είναι άμεση. Για να σχεδιάσουμε σωστά ένα σύστημα αναμονής ή ένα υπολογιστικό σύστημα, δεν αρκεί να γνωρίζουμε τη σημερινή συμπεριφορά του φόρτου. Πρέπει να μπορούμε να εκτιμήσουμε τον μελλοντικό φόρτο, ώστε να αποφασίσουμε:

- πόσους πόρους πρέπει να διαθέσουμε,
- πότε αναμένονται περίοδοι αυξημένης ζήτησης,
- πώς αποφεύγουμε συμφόρηση και bottlenecks,
- πώς αποφεύγουμε άσκοπη υπερδιαστασιολόγηση.

Αν ο φόρτος υποεκτιμηθεί, το σύστημα μπορεί να οδηγηθεί σε μεγάλες ουρές, αυξημένες καθυστερήσεις και πιθανή απώλεια ποιότητας υπηρεσίας. Αν υπερεκτιμηθεί, δεσμεύονται περισσότεροι πόροι από όσους χρειάζονται, άρα αυξάνεται το κόστος.

6.2 Δεδομένα και βασικό πρόβλημα πρόβλεψης

Η χρονοσειρά συμβολίζεται με:

$$Y_t,$$

όπου t είναι ο χρόνος σε ώρες. Στην άσκηση χρησιμοποιούνται οι πρώτες 1200 ώρες ως ιστορικό training set και γίνεται πρόβλεψη για τις επόμενες ώρες.

Η γενική μορφή του προβλήματος είναι η εξής: αφού έχουμε παρατηρήσει:

$$Y_1, Y_2, \dots, Y_t,$$

θέλουμε να προβλέψουμε μια μελλοντική τιμή:

$$Y_{t+\ell}.$$

Η πλήρης θεωρητική πρόβλεψη δεν είναι απλώς ένας αριθμός, αλλά η υπό συνθήκη κατανομή:

$$P(Y_{t+\ell} \mid Y_1, \dots, Y_t).$$

Η σημειακή πρόβλεψη είναι συνήθως η υπό συνθήκη μέση τιμή:

$$\hat{Y}_{t+\ell} = E(Y_{t+\ell} \mid Y_1, \dots, Y_t).$$

Όμως, επειδή το μέλλον είναι τυχαίο, μια πρόβλεψη πρέπει να συνοδεύεται και από μέτρο αβεβαιότητας. Για αυτό στην άσκηση ζητούνται 95% prediction intervals.

Ένα prediction interval έχει γενικά τη μορφή:

$$[\hat{Y}_{t+\ell} - c_\ell, \hat{Y}_{t+\ell} + c_\ell],$$

όπου το c_ℓ αυξάνεται συνήθως με τον ορίζοντα πρόβλεψης ℓ , επειδή όσο πιο μακριά προβλέπουμε, τόσο μεγαλύτερη είναι η αβεβαιότητα.

6.3 Prediction intervals και confidence intervals

Ένα κρίσιμο θεωρητικό σημείο είναι η διάκριση μεταξύ prediction intervals και confidence intervals.

- Το **confidence interval** αφορά αβεβαιότητα στην εκτίμηση μιας παραμέτρου ή μιας μέσης τιμής.
- Το **prediction interval** αφορά αβεβαιότητα για μια μελλοντική πραγματική παρατήρηση.

Τα prediction intervals είναι συνήθως πλατύτερα, επειδή πρέπει να λάβουν υπόψη όχι μόνο την αβεβαιότητα του μοντέλου, αλλά και την τυχαία διακύμανση της μελλοντικής τιμής.

Στην άσκηση, αυτό έχει πρακτική σημασία: δεν θέλουμε μόνο να πούμε ποια είναι η αναμενόμενη ζήτηση GPU, αλλά και μέσα σε ποιο εύρος είναι πιθανό να βρεθεί η πραγματική ζήτηση.

6.4 Μέθοδος 1: Γραμμική παλινδρόμηση

Η πρώτη μέθοδος είναι η γραμμική παλινδρόμηση. Η βασική ιδέα είναι ότι η χρονοσειρά αναλύεται σε δύο μέρη:

$$Y_t = f_t(\beta) + \epsilon_t.$$

Εδώ:

- $f_t(\beta)$ είναι το ντετερμινιστικό μέρος του μοντέλου,
- ϵ_t είναι ο τυχαίος θόρυβος,
- το μοντέλο είναι γραμμικό ως προς τις παραμέτρους β .

Προσοχή: η γραμμικότητα αφορά τις παραμέτρους, όχι απαραίτητα τον χρόνο. Μπορούμε να έχουμε όρους όπως t^2 , $\sin(2\pi t/T)$ και $\cos(2\pi t/T)$, και το μοντέλο να παραμένει γραμμικό ως προς τους συντελεστές.

Στην παρούσα άσκηση, επειδή τα δεδομένα είναι ωριαία, είναι φυσικό να εξετάζονται:

$$T = 24$$

για ημερήσια περιοδικότητα, και:

$$T = 168 = 7 \cdot 24$$

για εβδομαδιαία περιοδικότητα.

Ένα αντιπροσωπευτικό μοντέλο είναι:

$$Y_t = \beta_0 + \beta_1 t + \beta_2 \cos\left(\frac{2\pi t}{24}\right) + \beta_3 \sin\left(\frac{2\pi t}{24}\right) + \beta_4 \cos\left(\frac{2\pi t}{168}\right) + \beta_5 \sin\left(\frac{2\pi t}{168}\right) + \epsilon_t.$$

Το μοντέλο αυτό προσπαθεί να συλλάβει:

- αργή μακροχρόνια μεταβολή μέσω της τάσης,
- ημερήσια επανάληψη μέσω περιόδου 24,
- εβδομαδιαία επανάληψη μέσω περιόδου 168,
- τυχαίες αποκλίσεις μέσω των residuals.

Οι παράμετροι εκτιμώνται με ελάχιστα τετράγωνα. Αν τα σφάλματα είναι ανεξάρτητα, κανονικά και με σταθερή διασπορά, τότε η μέθοδος ελαχίστων τετραγώνων συμπίπτει με τη μέθοδο μέγιστης πιθανοφάνειας.

6.5 Residuals και overfitting στη γραμμική παλινδρόμηση

Τα residuals είναι:

$$e_t = Y_t - \hat{Y}_t.$$

Ερμηνεύονται ως το κομμάτι των δεδομένων που δεν εξηγείται από το μοντέλο. Σε ένα καλό μοντέλο, τα residuals πρέπει να μοιάζουν με θόρυβο, δηλαδή να μην εμφανίζουν έντονη συστηματική δομή.

Αν τα residuals έχουν τάση, εποχικότητα ή μεταβαλλόμενη διασπορά, τότε το μοντέλο δεν έχει συλλάβει όλη τη δομή της χρονοσειράς.

Ένα βασικό ζήτημα είναι το overfitting. Αν προσθέτουμε συνεχώς περισσότερες παραμέτρους, το μοντέλο μπορεί να προσαρμοστεί καλύτερα στο training set, αλλά να προβλέπει χειρότερα στο μέλλον.

Άρα:

καλύτερο fit στο training set $\nRightarrow$ καλύτερη πρόβλεψη.

Αυτό φαίνεται και στην αναφορά: ένα πιο σύνθετο regression μοντέλο μπορεί να έχει μικρότερο training error ή μικρότερα σημειακά σφάλματα, αλλά χειρότερο probabilistic score. Επομένως, η επιλογή μοντέλου δεν πρέπει να γίνεται μόνο με βάση το training MSE.

6.6 Μέθοδος 2: Φίλτρα και διαφοροποίηση

Η δεύτερη οικογένεια μεθόδων βασίζεται σε φίλτρα. Ένα φίλτρο είναι ένας γραμμικός, χρονικά αμετάβλητος και αιτιατός μετασχηματισμός μιας χρονοσειράς.

Η βασική ιδέα είναι ότι εφαρμόζουμε ένα φίλτρο ώστε να αφαιρέσουμε συστηματικά patterns, όπως τάση ή εποχικότητα. Αν το φιλτραρισμένο σήμα μοιάζει περισσότερο με λευκό θόρυβο ή με στάσιμη σειρά, τότε γίνεται πιο εύκολη η πρόβλεψη.

Χρησιμοποιούμε τον τελεστή οπισθοδρόμησης:

$$BY_t = Y_{t-1}.$$

Ο τελεστής διαφοροποίησης με υστέρηση s είναι:

$$\Delta_s = 1 - B^s.$$

Άρα:

$$\Delta_s Y_t = Y_t - Y_{t-s}.$$

Για ημερήσια εποχικότητα:

$$\Delta_{24} Y_t = Y_t - Y_{t-24},$$

ενώ για εβδομαδιαία εποχικότητα:

$$\Delta_{168} Y_t = Y_t - Y_{t-168}.$$

Η απλή διαφοροποίηση:

$$\Delta_1 Y_t = Y_t - Y_{t-1}$$

χρησιμοποιείται συχνά για αφαίρεση τάσης.

Στην άσκηση δοκιμάστηκαν φίλτρα όπως:

$$\Delta_{24}, \quad \Delta_1 \Delta_{24}, \quad \Delta_{168}, \quad \Delta_1 \Delta_{168}, \quad \Delta_{24} \Delta_{168}.$$

Το ζητούμενο είναι να βρεθεί φίλτρο που αφαιρεί αρκετή δομή χωρίς να καταστρέφει χρήσιμη πληροφορία.

6.7 Stationarity και over-differencing

Η έννοια της στασιμότητας είναι βασική στη θεωρία χρονοσειρών. Μια χρονοσειρά είναι στάσιμη όταν η στατιστική της συμπεριφορά δεν αλλάζει με τον χρόνο, δηλαδή έχει περίπου σταθερή μέση τιμή, σταθερή διασπορά και σταθερή δομή αυτοσυσχέτισης.

Τα φίλτρα βοηθούν στο να μετατρέψουμε μια μη στάσιμη σειρά σε πιο στάσιμη. Όμως, υπάρχει και ο κίνδυνος του over-differencing.

Over-differencing σημαίνει ότι εφαρμόζουμε περισσότερη διαφοροποίηση από όση χρειάζεται. Τότε:

- αφαιρούμε χρήσιμη δομή,
- αυξάνουμε τη μεταβλητότητα των residuals,
- χειροτερεύουμε την πρόβλεψη,
- παίρνουμε συχνά πλατύτερα ή λιγότερο αποτελεσματικά prediction intervals.

Στην αναφορά, τα φίλτρα που περιείχαν επιπλέον Δ_1 είχαν χειρότερη επίδοση. Αυτό ερμηνεύεται ως ένδειξη ότι η πρώτη διαφοροποίηση αφαίρεσε περισσότερη δομή από όση χρειαζόταν.

6.8 Πρόβλεψη με φίλτρα και αντίστροφο φίλτρο

Αν μετά το φιλτράρισμα έχουμε:

$$F(B)Y_t = c + \epsilon_t,$$

τότε για να προβλέψουμε τη μελλοντική τιμή $Y_{t+\ell}$ πρέπει ουσιαστικά να αντιστρέψουμε το φίλτρο.

Η πρόβλεψη με φίλτρα βασίζεται στις παρελθοντικές τιμές της ίδιας της χρονοσειράς. Για παράδειγμα, ένα εβδομαδιαίο φίλτρο Δ_{168} χρησιμοποιεί την ιδέα ότι η τιμή μιας ώρας μπορεί να σχετίζεται έντονα με την αντίστοιχη ώρα της προηγούμενης εβδομάδας.

Στα φίλτρα, η αβεβαιότητα των προβλέψεων συχνά μεγαλώνει με τον ορίζοντα πρόβλεψης, επειδή τα μελλοντικά σφάλματα συσσωρεύονται μέσω της αντίστροφης αναπαράστασης του φίλτρου.

6.9 Μετρικές αξιολόγησης

Για τη σύγκριση των μοντέλων χρησιμοποιούνται διαφορετικές μετρικές.

Το Mean Absolute Error είναι:

$$MAE = \frac{1}{m} \sum_{i=1}^m |Y_i - \hat{Y}_i|.$$

Το Root Mean Squared Error είναι:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (Y_i - \hat{Y}_i)^2}.$$

Το MAE μετρά μέσο απόλυτο σφάλμα, ενώ το $RMSE$ τιμωρεί περισσότερο τα μεγάλα σφάλματα, επειδή τα τετραγωνίζει.

Η κάλυψη των prediction intervals είναι:

$$Coverage = \frac{\#\{Y_i \in [L_i, U_i]\}}{m}.$$

Για 95% prediction intervals, θέλουμε η κάλυψη να είναι κοντά στο 95%. Αν είναι πολύ μικρότερη, τα διαστήματα είναι υπερβολικά στενά. Αν είναι πολύ μεγαλύτερη, μπορεί να είναι υπερβολικά συντηρητικά.

Η πιο σημαντική μετρική της άσκησης είναι το CRPS, δηλαδή Continuous Ranked Probability Score. Το CRPS αξιολογεί ολόκληρη την προβλεπτική κατανομή και όχι μόνο τη σημειακή πρόβλεψη. Μικρότερο CRPS σημαίνει καλύτερη πιθανοτική πρόβλεψη.

Για κανονική προβλεπτική κατανομή:

$$N(\mu, \sigma^2),$$

το CRPS υπολογίζεται από:

$$CRPS = \sigma \left[a(2\Phi(a) - 1) + 2\phi(a) - \frac{1}{\sqrt{\pi}} \right],$$

όπου:

$$a = \frac{y - \mu}{\sigma}.$$

Το πλεονέκτημα του CRPS είναι ότι λαμβάνει υπόψη και την ακρίβεια της σημειακής πρόβλεψης και το εύρος της αβεβαιότητας. Έτσι αποφεύγουμε να επιλέξουμε μοντέλο που έχει καλές σημειακές προβλέψεις αλλά κακά prediction intervals.

6.10 Ποιοτική ερμηνεία των αποτελεσμάτων της αναφοράς

Στην κατηγορία της γραμμικής παλινδρόμησης, το καλύτερο μοντέλο με βάση το median CRPS ήταν:

$$LR3 : \text{linear trend} + \text{daily } 24 + \text{weekly } 168.$$

Το μοντέλο αυτό είναι ποιοτικά εύλογο, επειδή η χρονοσειρά είναι ωριαία και άρα αναμένουμε τόσο ημερήσια όσο και εβδομαδιαία επανάληψη. Δεν είναι υπερβολικά απλό, γιατί περιλαμβάνει τις δύο βασικές περιοδικότητες, αλλά ούτε υπερβολικά σύνθετο, γιατί αποφεύγει επιπλέον αρμονικές που μπορεί να οδηγήσουν σε overfitting.

Στην κατηγορία των φίλτρων, το καλύτερο φίλτρο ήταν:

$$F3 = \Delta_{168}.$$

Αυτό δείχνει ότι η εβδομαδιαία εποχικότητα είναι σημαντική στα δεδομένα. Το φίλτρο χρησιμοποιεί τη διαφορά με την αντίστοιχη ώρα της προηγούμενης εβδομάδας και έτσι εκμεταλλεύεται ένα βασικό pattern της χρονοσειράς.

Η τελική σύγκριση έδειξε ότι το $LR3$ υπερέχει του $F3$ στις βασικές μετρικές. Και τα δύο μοντέλα είχαν επαρκή κάλυψη των prediction intervals, αλλά το regression πέτυχε μικρότερο median CRPS. Άρα έδωσε καλύτερο συμβιβασμό μεταξύ ακρίβειας και αβεβαιότητας.

Ένα ακόμη σημαντικό συμπέρασμα είναι ότι τα μοντέλα δεν μπορούν να προβλέψουν αξιόπιστα απότομες αιχμές. Οι αιχμές μπορεί να αντιστοιχούν σε έκτακτα γεγονότα ή σπάνιες μεγάλες εργασίες. Ένα απλό μοντέλο τάσης και εποχικότητας μπορεί να συλλάβει τη μέση δομή, αλλά όχι απαραίτητα ακραία spikes.

Για αυτό τα prediction intervals είναι απαραίτητα. Η σημειακή πρόβλεψη δείχνει την αναμενόμενη τιμή, αλλά το διάστημα πρόβλεψης αποτυπώνει το εύρος της πιθανής απόκλισης.

6.11 Κρίσιμα σημεία για την προφορική εξέταση

Τα σημεία που πρέπει να μπορεί κανείς να εξηγήσει άμεσα είναι:

1. Το forecasting χρησιμοποιείται για capacity planning και αποφυγή συμφόρησης.
2. Η πρόβλεψη δεν είναι μόνο σημειακή τιμή, αλλά και αβεβαιότητα.
3. Τα prediction intervals δεν είναι ίδια με confidence intervals.
4. Η linear regression μοντελοποιεί τη χρονοσειρά ως τάση, εποχικότητα και θόρυβο.
5. Τα ημίτονα και συνημίτονα χρησιμοποιούνται για περιοδικότητα.
6. Το overfitting σημαίνει καλύτερη προσαρμογή στο training set αλλά πιθανώς χειρότερη πρόβλεψη.
7. Τα φίλτρα αφαιρούν τάση ή εποχικότητα μέσω differencing.
8. Ο backshift operator είναι ο βασικός τελεστής για τη μαθηματική αναπαράσταση φίλτρων.
9. Το over-differencing αφαιρεί υπερβολικά πολλή δομή και μπορεί να χειροτερεύσει τις προβλέψεις.

10. Το CRPS αξιολογεί probabilistic forecasts και όχι μόνο σημειακό σφάλμα.
11. Η κάλυψη των prediction intervals πρέπει να είναι κοντά στο ονομαστικό επίπεδο.
12. Οι αιχμές είναι δύσκολες στην πρόβλεψη και πρέπει να αντιμετωπίζονται ως μέρος της αβεβαιότητας.

6.12 Πιθανά θεωρητικά ερωτήματα προφορικής εξέτασης

1. Γιατί υπάρχει forecasting σε μάθημα συστημάτων αναμονής;

Επειδή ο σχεδιασμός ενός συστήματος αναμονής απαιτεί εκτίμηση του μελλοντικού φόρτου. Αν γνωρίζουμε ή προβλέπουμε τη ζήτηση, μπορούμε να κάνουμε καλύτερο capacity planning και να αποφύγουμε συμφόρηση ή υπερδιαστασιολόγηση.

2. Τι σημαίνει σημειακή πρόβλεψη;

Είναι ένας μοναδικός αριθμός που εκτιμά τη μελλοντική τιμή, συνήθως:

$$\hat{Y}_{t+l} = E(Y_{t+l} | Y_1, \dots, Y_t).$$

3. Γιατί δεν αρκεί μόνο η σημειακή πρόβλεψη;

Επειδή η μελλοντική τιμή είναι τυχαία. Δύο μοντέλα μπορεί να έχουν παρόμοια σημειακή πρόβλεψη αλλά διαφορετική αβεβαιότητα. Για αυτό χρειαζόμαστε prediction intervals.

4. Ποια είναι η διαφορά prediction interval και confidence interval;

Το confidence interval αφορά μια παράμετρο ή μέση τιμή. Το prediction interval αφορά μια μελλοντική πραγματική παρατήρηση. Για αυτό το prediction interval είναι συνήθως πιο πλατύ.

5. Τι σημαίνει 95% prediction interval;

Σημαίνει ότι, υπό τις υποθέσεις του μοντέλου, περίπου το 95% των μελλοντικών πραγματικών τιμών πρέπει να βρίσκεται μέσα στο διάστημα.

6. Ποια είναι η βασική μορφή linear regression μοντέλου;

$$Y_t = f_t(\beta) + \epsilon_t.$$

Το $f_t(\beta)$ περιγράφει τη δομή, ενώ το ϵ_t είναι ο θόρυβος.

7. Τι σημαίνει ότι το regression είναι γραμμικό ως προς τις παραμέτρους;
Σημαίνει ότι οι άγνωστες παράμετροι εμφανίζονται γραμμικά. Το μοντέλο μπορεί να περιέχει μη γραμμικές συναρτήσεις του χρόνου, όπως t^2 , $\sin(\cdot)$ ή $\cos(\cdot)$, αλλά παραμένει γραμμικό ως προς τους συντελεστές.

8. Γιατί χρησιμοποιούμε $\sin$ και $\cos$ στη χρονοσειρά;

Για να μοντελοποιήσουμε περιοδικότητα. Για ωριαία δεδομένα, περίοδος 24 αντιστοιχεί σε ημερήσιο μοτίβο και περίοδος 168 σε εβδομαδιαίο μοτίβο.

9. Γιατί είναι λογικό το μοντέλο με daily και weekly periodicity;

Επειδή σε συστήματα φόρτου υπάρχουν συχνά επαναλαμβανόμενα ημερήσια και εβδομαδιαία patterns, π.χ. διαφορετική χρήση ανά ώρα της ημέρας και ανά ημέρα της εβδομάδας.

10. Τι είναι residuals;

Είναι οι διαφορές πραγματικών και προβλεπόμενων τιμών:

$$e_t = Y_t - \hat{Y}_t.$$

Χρησιμοποιούνται για να ελέγξουμε αν το μοντέλο άφησε ανεξήγητη συστηματική δομή.

11. Τι σημαίνει overfitting;

Σημαίνει ότι το μοντέλο προσαρμόζεται υπερβολικά στο training set και μαθαίνει τυχαίες διακυμάνσεις αντί για γενική δομή. Αυτό μπορεί να μειώνει το training error αλλά να χειροτερεύει την πρόβλεψη.

12. Γιατί ένα μοντέλο με μικρότερο training MSE δεν είναι απαραίτητα καλύτερο;

Επειδή το training MSE μετρά προσαρμογή στα ιστορικά δεδομένα, όχι ικανότητα πρόβλεψης. Ένα πολύ σύνθετο μοντέλο μπορεί να έχει μικρότερο training MSE αλλά χειρότερη γενίκευση.

13. Τι είναι φίλτρο σε χρονοσειρά;

Είναι ένας μετασχηματισμός της σειράς που αφαιρεί ή απομονώνει συγκεκριμένα χαρακτηριστικά, όπως τάση ή εποχικότητα, ώστε το υπόλοιπο να είναι πιο εύκολο να προβλεφθεί.

14. Τι είναι ο backshift operator;

Είναι ο τελεστής:

$$BY_t = Y_{t-1}.$$

Χρησιμοποιείται για να γράφουμε φίλτρα και διαφοροποιήσεις με συμπαγή μαθηματικό τρόπο.

15. Τι κάνει ο τελεστής Δ_s ;

Ορίζεται ως:

$$\Delta_s = 1 - B^s.$$

Άρα:

$$\Delta_s Y_t = Y_t - Y_{t-s}.$$

Αφαιρεί εποχικότητα με περίοδο s .

16. Τι σημαίνει Δ_{24} και τι σημαίνει Δ_{168} ;

Το Δ_{24} αφαιρεί ημερήσια εποχικότητα σε ωριαία δεδομένα, ενώ το Δ_{168} αφαιρεί εβδομαδιαία εποχικότητα.

17. Τι είναι over-differencing;

Είναι η υπερβολική διαφοροποίηση μιας χρονοσειράς. Αφαιρεί χρήσιμη δομή, αυξάνει τη μεταβλητότητα των residuals και μπορεί να χειροτερεύσει τις προβλέψεις.

18. Γιατί το φίλτρο Δ_{168} ήταν λογικό για τα δεδομένα;

Επειδή τα δεδομένα είναι ωριαία και η ζήτηση πόρων μπορεί να επαναλαμβάνεται εβδομαδιαία. Το Δ_{168} αξιοποιεί την αντίστοιχη ώρα της προηγούμενης εβδομάδας.

19. Τι είναι MAE;

Είναι το μέσο απόλυτο σφάλμα:

$$MAE = \frac{1}{m} \sum_{i=1}^m |Y_i - \hat{Y}_i|.$$

Μετρά το μέσο μέγεθος του σφάλματος χωρίς να δίνει υπερβολικό βάρος σε μεγάλες αποκλίσεις.

20. Τι είναι RMSE;

Είναι:

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (Y_i - \hat{Y}_i)^2}.$$

Τιμωρεί περισσότερο τα μεγάλα σφάλματα από το MAE.

21. Τι μετρά το coverage;

Μετρά το ποσοστό των πραγματικών τιμών που βρίσκονται μέσα στα prediction intervals. Για 95% intervals θέλουμε coverage κοντά στο 95%.

22. Τι είναι το CRPS;

Είναι μετρική αξιολόγησης πιθανοτικής πρόβλεψης. Δεν αξιολογεί μόνο τη σημειακή πρόβλεψη, αλλά ολόκληρη την προβλεπτική κατανομή. Μικρότερο CRPS σημαίνει καλύτερη πρόβλεψη.

23. Γιατί στην αναφορά επιλέγουμε μοντέλο με βάση το median CRPS;

Επειδή ενδιαφερόμαστε για συνολική ποιότητα πρόβλεψης: και για ακρίβεια και για σωστή αβεβαιότητα. Το median CRPS είναι πιο κατάλληλο από ένα καθαρά σημειακό σφάλμα όταν αξιολογούνται prediction intervals.

24. Γιατί το LR3 θεωρήθηκε καλύτερο από το F3;

Επειδή είχε καλύτερες βασικές μετρικές σφάλματος και μικρότερο median CRPS, ενώ είχε παρόμοια κάλυψη prediction intervals. Άρα πέτυχε καλύτερο συμβιβασμό ανάμεσα σε ακρίβεια και αβεβαιότητα.

25. Γιατί τα spikes είναι δύσκολο να προβλεφθούν;

Επειδή συχνά αντιστοιχούν σε έκτακτα ή σπάνια γεγονότα που δεν εξηγούνται από

ομαλή τάση ή περιοδικότητα. Ένα απλό μοντέλο μπορεί να προβλέψει τη μέση δομή, όχι απαραίτητα ακραίες αιχμές.

26. Ποιο είναι το βασικό πρακτικό συμπέρασμα της άσκησης;

Για capacity planning δεν πρέπει να βασιζόμαστε μόνο σε σημειακές προβλέψεις. Πρέπει να αξιολογούμε και την αβεβαιότητα, γιατί αυτή καθορίζει πόσο ασφαλές είναι το σύστημα απέναντι σε μελλοντικές αιχμές.